

学号：_____

密级：__

硕士研究生学位论文

知识点强化表征驱动的知识追踪模型 研究

专 业： 计算机科学与技术

研究方向： 机器学习与人工智能

研 究 生：

指导教师：

论文起止日期：2025 年 2 月至 2026 年 3 月

学号：_____

密级：__

硕士研究生学位论文

知识点强化表征驱动的知识追踪模型 研究

专 业： 计算机科学与技术

研究方向： 机器学习与人工智能

研 究 生：

指导教师：

论文起止日期：2025 年 2 月至 2026 年 3 月

A Study on a Knowledge Representation-Driven Knowledge Tracing Model

Major: Computer Science and Technology

Direction of Study: Machine Learning and Artificial
Intelligence

Graduate Student:

Supervisor:

School of Computer Science

February,2025 to March,2026

摘要

传统教学模式通常采用统一的教学进度与内容，难以充分适应学生在认知水平、学习节奏和知识掌握情况等方面的个体差异。同时，线下教学场景往往缺乏对学习过程的持续监测与实时反馈机制，使得教师难以及时识别学生的知识薄弱点并提供针对性指导。随着在线教育平台的快速发展，基于数据驱动的个性化教学逐渐成为可能，而其有效实施在很大程度上依赖于对学习过程的精准建模能力。

知识追踪作为实现个性化教学与智能导学系统的关键任务，旨在通过学习者的历史作答序列动态推断其知识状态，并预测其未来表现，从而为自适应学习决策提供支持。在现有研究中，知识点的表征质量及其相互关系的建模方式被视为影响模型性能的核心因素。尽管已有研究引入图神经网络对知识结构进行建模，在一定程度上提升了模型的表达能力，但其多跳依赖通常通过层叠消息传递隐式实现，导致不同阶的邻域信息在传播过程中被混合聚合，缺乏显式区分与可控建模，难以刻画多跳依赖对知识状态演化的差异化影响。此外，现有方法通常将邻域知识点视为同质节点进行更新，缺乏对信息质量与影响方向的有效筛选，可能引入噪声干扰；同时，多数模型仍基于静态监督学习范式训练，一旦完成训练，其决策机制难以根据学习过程的动态变化进行自适应调整。

针对上述问题，本文提出一种基于知识点强化表征的知识追踪模型。该模型聚焦于知识点表征进行建模，从结构化建模与决策机制两个层面进行系统改进。具体而言，本文的主要贡献包括以下三方面：

（1）针对邻域信息质量区分不足的问题，引入三支决策理论，将知识点的邻域划分为正域、边界域与负域，并设计差异化的信息传递与聚合策略，以抑制噪声干扰、增强表征的稳定性与鲁棒性。

（2）针对多跳依赖隐式混合建模的局限，提出多阶邻域显式建模机制，通过分离不同阶数的邻域并引入距离衰减权重，刻画多跳邻域对目标知识点状态的差异化影响，在引入深层依赖的同时抑制远邻噪声。

（3）针对静态监督学习适应性不足的问题，引入强化学习框架，将知识状态更新过程建模为序列决策问题，借助奖励信号动态调整模型决策策略，从而提升对学习过程动态变化的自适应能力。

在实验中，本文在多个真实教育数据集上对所提模型进行了系统评估，并与一系列经典及前沿的知识追踪模型进行了对比。实验结果表明，本文模型在作答预测、状态表示质量及稳定性方面均表现优异。进一步的消融实验验证了各模块的有效性；可视化与可解释性分析表明，模型能够清晰呈现知识状态的演化过程，并为预测结果提供结构化的解释。

未来工作将围绕知识结构的扩展、学习行为信息的深度融合以及多模态数据的引入等方面展开，以进一步加强对复杂学习过程的刻画能力，持续推动知识追踪在个性化教学场景中的应用落地。

关键词：知识追踪，三支决策，强化学习，知识点表示，图神经网络

Abstract

Traditional instructional paradigms typically adopt a unified teaching schedule and standardized content delivery, which makes it difficult to adequately accommodate individual differences among students in terms of cognitive level, learning pace, and knowledge mastery. Meanwhile, offline educational settings often lack continuous monitoring and real-time feedback mechanisms for the learning process, preventing teachers from promptly identifying students' knowledge deficiencies and providing targeted guidance. With the rapid development of online educational platforms, data-driven personalized instruction has gradually become feasible. However, its effective implementation largely depends on the accurate modeling of the learning process.

Knowledge Tracing (KT), as a key task for personalized education and intelligent tutoring systems, aims to dynamically infer learners' knowledge states from their historical response sequences and predict future performance, thereby supporting adaptive learning decisions. In existing research, the quality of knowledge concept representations and the modeling of their interrelationships are widely regarded as critical factors affecting model performance. Although recent studies have introduced graph neural networks (GNNs) to model knowledge structures and improve representational capacity, multi-hop dependencies are typically captured implicitly through stacked message-passing layers. As a result, neighborhood information from different orders is often mixed during propagation, lacking explicit differentiation and controllable modeling, which makes it difficult to characterize the heterogeneous influence of multi-hop dependencies on knowledge state evolution. Furthermore, most existing methods treat neighboring knowledge concepts as homogeneous nodes during updates, without effectively distinguishing information quality or influence direction, potentially introducing noise. In addition, the majority of models are trained under a static supervised learning paradigm; once training is completed, their decision mechanisms remain fixed and cannot adaptively adjust to dynamic changes in the learning process.

To address these limitations, this paper proposes a knowledge tracing model based on enhanced knowledge representation. The proposed framework focuses on modeling knowledge concept representations and introduces systematic improvements from both structural modeling and decision-making perspectives. Specifically, the main contributions of this work are threefold:

(1) To address the insufficient differentiation of neighborhood information quality, Three-Way Decision Theory is introduced to partition the neighborhood of each knowledge concept into positive, boundary, and negative regions. Distinct information propagation and aggregation strategies are designed for each region to suppress noise interference and enhance the stability and robustness of knowledge representations.

(2) To overcome the limitations of implicit mixed modeling of multi-hop dependencies, an explicit multi-order neighborhood modeling mechanism is proposed. By separating neighborhoods of different orders and incorporating distance-decay weighting, the model captures the differentiated influence of multi-hop neighbors on the target knowledge state while mitigating noise from distant nodes.

(3) To improve the limited adaptability of static supervised learning paradigms, a reinforcement learning framework is incorporated. The knowledge state updating process is formulated as a sequential decision-making problem, where reward signals are leveraged to dynamically adjust model strategies, thereby enhancing adaptability to the evolving learning process.

Extensive experiments are conducted on multiple real-world educational datasets, where the proposed model is systematically evaluated against a range of classical and state-of-the-art knowledge tracing approaches. Experimental results demonstrate that the proposed model achieves superior performance in response prediction accuracy, representation quality, and stability. Further ablation studies validate the effectiveness of each module. Visualization and interpretability analyses indicate that the model can clearly illustrate the evolution of knowledge states and provide structured explanations for its predictions.

Future work will focus on extending knowledge structure modeling, deeply integrating rich learning behavior information, and incorporating multimodal data to further enhance the modeling of complex learning processes and promote the practical deployment of knowledge tracing in personalized education.

Keywords: Knowledge Tracing, Three-Way Decision, Reinforcement Learning, Knowledge Representation, Graph Neural Networks

目 录

摘 要	I
Abstract	III
第 1 章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.3 本文的研究内容	7
1.4 本文的组织结构	8
第 2 章 相关理论基础	10
2.1 知识追踪	10
2.2 注意力机制	12
2.3 图神经网络	13
2.4 强化学习	15
2.5 三支决策	19
2.6 本章小结	21
第 3 章 知识点强化表征驱动的知识追踪模型	23
3.1 模型思想与问题提出	23
3.2 模型架构	26
3.3 多阶三支决策的知识点强化表征网络	26
3.4 基于 Actor-Critic 的模型训练方法	30
3.5 模型训练算法	31
3.6 本章小结	31
第 4 章 实验	32
4.1 实验设置	32
4.2 预测性能对比实验	34
4.3 消融实验	35
4.4 超参数敏感性分析	36
4.5 可视化分析实验	36
4.6 本章小结	37
第 5 章 总结与展望	38
5.1 论文工作总结	38
5.2 未来研究展望	38
致 谢	39

参 考 文 献.....	40
个 人 简 介.....	46

第1章 绪论

1.1 研究背景和意义

随着信息技术的快速发展和在线教育平台的广泛应用，教学活动正逐步从传统线下课堂向数字化、智能化方向转型。在线学习环境能够持续记录学习者在学习过程中产生的大量行为数据，如作答结果、作答顺序和学习频率等，这为深入分析学习过程、实现个性化教学提供了重要的数据基础。然而，如何从这些复杂、多样且具有时序性的行为数据中准确推断学习者的知识状态，仍然是智能教育领域面临的核心挑战。

在传统教学模式中，教学进度和内容通常以班级为单位统一设计，难以充分考虑学生在认知能力、知识基础和学习节奏等方面的个体差异。同时，线下教学往往缺乏对学习过程的持续监测与即时反馈机制，教师大多只能通过阶段性考试或作业结果来了解学生的学习情况，难以及时发现学生的知识薄弱点并提供针对性指导。这种以结果为导向的反馈方式，在一定程度上影响了教学干预的及时性和有效性。

在线教育平台的兴起为解决上述问题提供了新的可能。通过持续记录并分析学习者在平台上的学习行为，能够实现对学习过程的动态监测与精细化建模，从而为个性化教学与智能辅导提供技术支持。在此背景下，**知识追踪**作为智能教育系统中的关键技术，逐渐成为教育数据挖掘与学习分析领域的研究热点。知识追踪旨在基于学习者的历史作答序列，动态刻画其对不同知识点的掌握状态，并预测其未来的作答表现，从而为自适应教学策略制定、学习路径推荐及学习诊断等任务提供依据。

近年来，随着深度学习技术的发展，研究者从序列建模、注意力机制和图结构建模等多个角度对知识追踪问题进行了探索，并在预测性能方面取得了进展。然而，现有方法在复杂学习场景下仍面临诸多挑战，其中，知识点邻域信息质量区分不足、多跳依赖建模不充分以及静态监督学习范式适应性不足，是制约现有知识追踪模型性能提升的三个核心问题，也是本文研究的出发点。

一方面，知识点作为知识追踪的基本建模单元，其表征质量直接影响模型对学习者的知识状态的刻画能力。现有研究多采用嵌入向量表示知识点，或通过引入题目属性与知识点关系对其进行增强。然而，在复杂学习场景中，不同知识点在学习过程中的作用存在显著差异，简单统一的表征方式难以全面反映其在具体上下文中的影响特征。若知识点表征缺乏足够的判别性与稳定性，模型在状态更新过程中容易受到噪声干扰，从而影响预测结果的可靠性。

另一方面，知识点之间往往并非相互独立，而是通过先修关系、相似关系等构成复杂的知识网络。学习者对某一知识点的掌握情况，不仅受其直接相关知识

点的影响,还可能间接受到更深层知识点的作用。尽管已有研究引入图神经网络对知识点关系进行建模,在一定程度上增强了对知识结构的刻画能力,但其多跳依赖通常通过层叠消息传递机制隐式实现,不同阶的邻域信息在传播过程中往往被混合聚合,缺乏显式区分与可控建模,难以准确刻画多跳依赖对知识状态演化的差异化影响。此外,邻域知识点在状态更新过程中常被同等对待,未能有效区分哪些邻居具有促进、不确定或干扰作用,这也限制了模型在复杂知识结构下的表达能力。

与此同时,大多数现有知识追踪模型基于监督学习范式进行训练,其决策机制在训练完成后趋于固定,难以根据学习过程中的动态变化进行自适应调整。在真实学习场景中,学习者的知识状态、学习策略以及知识点间的作用关系均可能随时间发生演变,静态建模方式在一定程度上制约了模型对学习过程动态特征的刻画能力。

基于上述背景,本文围绕**知识点强化表征与知识点相互作用建模**这一核心问题展开研究,提出一种知识点强化表征驱动的知识追踪模型。通过引入结构化决策机制对知识点邻域进行差异化建模,并结合多阶邻域信息与自适应优化策略,提升模型对复杂知识结构与动态学习过程的刻画能力。

从理论层面看,本文研究有助于深化对知识点表征及其协同作用机制的理解,为知识追踪中的多阶邻域建模与结构化决策提供新思路;从应用层面看,所提方法能够更准确地刻画学习者知识状态的演变过程,为个性化教学干预、智能导学系统设计与学习诊断提供更可靠的技术支持,具有一定的实践价值。

1.2 国内外研究现状

知识追踪作为智能教育的核心任务,旨在通过学习者的历史作答序列动态推断其知识状态,并预测其未来表现。近年来,随着深度学习技术的发展,知识追踪领域涌现出大量基于神经网络的方法,在预测性能上取得了显著进展。本节将从基于深度学习的知识追踪方法、基于图神经网络的知识追踪方法以及基于强化学习的决策优化方法三个方面对国内外研究现状进行综述。

1.2.1 基于深度学习的知识追踪方法

传统知识追踪方法主要包括贝叶斯知识追踪(Bayesian Knowledge Tracing, BKT)[8]和项目反应理论(Item Response Theory, IRT)[9]等。BKT 假设学习者对每个知识点的掌握状态为二值变量,通过隐马尔可夫模型建模知识状态的转移过程。IRT 则通过建立学习者能力参数与题目难度参数之间的函数关系来预测作答结果。然而,这些传统方法依赖严格的假设条件,难以充分刻画复杂学习过程中的非线性特征与知识点相互作用关系。

随着深度学习技术的快速发展,研究者开始探索利用神经网络建模知识追踪任务。Piech 等人[12]于 2015 年首次提出深度知识追踪模型(Deep Knowledge Tracing, DKT),利用长短期记忆网络(LSTM)对学习者的作答序列进行建模,实现了对知识状态的动态追踪,在预测性能上显著优于传统方法,开创了深度学习在知识追踪领域应用的先河。此后,研究者从多个角度对 DKT 进行改进。Zhang 等人[15]提出动态键值记忆网络(Dynamic Key-Value Memory Networks, DKVMN),通过引入记忆机制建立全局知识点状态矩阵,在一定程度上缓解了循环神经网络难以建模长期依赖的问题。李晓光等人[16]提出融合学习与遗忘机制的深度知识追踪模型(LFKT),通过建模学习者的遗忘行为来增强知识状态表征的准确性。宗晓萍等人[17]基于掌握速度对知识追踪模型进行改进,考虑了学习者在不同知识点上的学习速度差异。

(1) 基于循环网络的知识追踪方法

基于循环网络的知识追踪方法通常首先对题目进行表示,再将题目表示按时间顺序输入循环网络,将历史信息融入当前时刻的题目表示,建模给定当前时刻题目信息条件下作答结果的条件概率分布。这类方法的主要特点在于利用知识点、学习行为等不同信息增强对题目的表征。

李浩君等人[9]提出基于自注意力机制和双向 GRU 神经网络的深度知识追踪优化模型(KTSA-BiGRU),通过双向循环网络捕获历史答题序列特征,增强当前题目的表征。周东岱等人[10]基于双流结构和多知识点映射结构对深度知识追踪模型进行改进(DKTDM),使用若干学习行为特征增强题目表征。王士进等人[11]提出端到端的深度学生知识画像建模方法(DKP),通过建模可靠性来增强题目表示。王文涛等人[12]提出基于上下文表示的知识追踪方法(KTCR),使用 Q 矩阵将题目映射为知识点,再将正确率等上下文信息融入知识点的表示,实现对题目信息的增强。Liu 等人[14]提出练习感知的知识追踪模型(EKT),通过提取题目的语义特征与知识点表征矩阵结合,更加充分地表示题目中包含的知识点。琚生根等人[13]提出多知识点融合嵌入的深度知识追踪模型(MCAKT),使用 Transformer 架构建模目标知识点,其中的多头注意力和位置编码减少了历史知识点对目标知识点建模表示的长期依赖问题。赵琰等人[20]提出可靠响应表示增强的知识追踪方法(KTR),通过建模答题响应的可靠性来提升预测性能。陈成等人[19]提出融合知识与能力的深度知识追踪模型(FKA-DKT),建模能力向量与知识向量融合,增强题目表征。

这类研究在增强题目表征的基础上,利用循环网络使用历史信息增强当前信息,从而预测给定题目信息条件下学习者作答结果的条件概率分布。然而,循环网络在建模长期依赖方面存在固有局限,难以充分捕捉作答序列中的远距离依赖关系。

(2) 基于注意力机制的知识追踪方法

为了克服循环网络的局限性,研究者引入注意力机制来建模知识追踪任务。这类方法一般首先建立题目与知识点的关系,利用知识点来表示题目,再对全局知识

点施加注意力机制,将全局知识点信息根据权重系数融入当前时刻的题目表示,建模给定当前时刻题目信息条件下作答结果的条件概率分布。

Pandey 等人[18]首次将自注意力机制引入知识追踪(SAKT),通过建模作答序列中任意两个时间步之间的关系来解决题目数据稀疏的问题。Huang 等人[16]提出融合时间和因果信息的知识追踪模型(TCKT),使用因果注意力机制增强表示目标知识点,以获取知识点的一致性表示。贾瑞等人[21]提出知识点相关性与遗忘程度融合的深度知识追踪模型(RFKT),使用相关性表示知识点,通过注意力机制建模知识点的演化过程来对题目进行增强表征。Choi 等人[17]提出 SAINT 模型,使用 Transformer 架构分别将题目与作答结果作为编码器和解码器的输入,能够捕获复杂的题目与作答结果之间的关系。许智宏等人[22]提出问题特征增强的知识追踪模型(QFEKT),通过图卷积神经网络结合对比学习的方式聚合目标知识点的邻居信息,从而增强题目表示。Pu 等人[42]提出增强局部性的注意力知识追踪模型(ELAKT),通过引入局部性增强机制来提升注意力机制的有效性。

这类研究利用注意力机制,使用加权的全局信息增强表示当前题目,从而预测给定当前题目信息条件下学习者作答结果的条件概率分布。相较于循环网络,注意力机制能够更好地建模长距离依赖关系,但在建模知识点之间结构化关系方面仍存在不足。

1.2.2 基于图神经网络的知识追踪方法

知识点之间往往存在先修关系、相似关系等复杂的结构化依赖,这种结构信息对于准确建模学习者的知识状态具有重要意义。图神经网络作为一种能够有效建模结构化数据的深度学习方法,近年来被广泛应用于知识追踪任务中。基于图神经网络的知识追踪方法的主要特点在于将题目分解为若干知识点,通过图神经网络对知识点的更新来增强题目的表征,最终获取给定题目信息条件下作答结果的条件概率。

Nakagawa 等人[28]提出基于图的知识追踪模型(GKT),使用图结构表示知识点,并利用图神经网络的聚合和更新操作建模知识点的表示,为后续研究奠定了基础。Song 等人[18]提出联合图卷积网络的深度知识追踪模型(JKT),通过建模知识点之间的关系来增强知识状态表征。Gan 等人^[19]提出知识结构增强的图表示学习模型,利用注意力机制对知识结构进行建模。Yang 等人[20]提出基于异构图的知识追踪模型,融合时空演化信息来刻画知识状态的动态变化。Ni 等人[21]构建学习者-题目交互的异构图神经网络模型(HHSKT),通过建模学习者与题目之间的交互关系来提升预测性能。

进一步地,研究者探索了更复杂的图结构建模方法。Abdelrahman 等人[24]提出深度图记忆网络(Deep Graph Memory Networks, DGMN),建立了潜在概念图表示知识点之间的关系,使用图卷积网络捕捉知识点之间的依赖关系。董永峰等人[25]

提出融合 IRT 的图注意力深度知识追踪模型(GAKT-IRT),在图卷积网络的基础上引入图注意力机制(GAT),能够为邻居节点分配不同的权重,注意到邻居节点对中心节点的影响程度。闫秋艳等人[26]提出基于学生-问题关联的异构图知识追踪模型(SPKT),采用多头注意力机制聚合异质节点的邻域信息,并通过全连接网络将异质邻居特征与中心节点属性相融合。张凯等人[27]提出时空相关性融合表征的知识追踪模型(TSKT),使用图注意力网络结合时间信息和空间信息来表征知识点。Yang 等人[29]和 Song 等人[30]分别提出 GIKT 和 GKT-FM 模型,使用类似的图神经网络方法对知识点进行建模。郑浩东等人[31]提出融合遗忘因素与记忆门的图神经网络知识追踪模型(GKT-FM),通过引入遗忘机制来增强模型的表达能力。

为了建模知识点之间的多种关系,Duan 等人[32]提出融合多知识关系的深度知识追踪模型(DKTMR),通过图生成对抗网络实现对知识点的多关系表征,在一定程度上提升了模型对复杂知识结构的刻画能力。秦晨等人[33]提出图注意力增强的知识追踪模型(GAKT),建立题目与知识点组成的二分图,使用图注意力网络更新知识点的表示。崔晨等人[34]提出双图知识追踪模型(DGEKT),利用超图和有向图的双图结构捕获题目与知识点的关联关系,增强题目与知识点的表示。Song 等人[23]提出双图对比学习知识追踪模型(Bi-CLKT),在知识点的级别和图级别分别应用图卷积网络,再通过对比学习来增强知识点的表示。

近期研究进一步关注知识图谱嵌入与深度学习的融合。Tang 等人[43]提出基于增强知识图谱嵌入的深度知识追踪方法,通过构建包含学生、题目和技能三类实体的知识图谱,并对三类节点及其属性进行嵌入来捕获复杂关系,在 EdNet 数据集上相比 DKT 模型在 ACC 和 AUC 指标上分别提升了 10.2%和 9.08%。

尽管基于图神经网络的方法在建模知识点结构关系方面取得了进展,但现有研究仍存在以下不足:第一,现有方法将邻域知识点视为同质节点,缺乏对邻域信息质量的有效区分,可能引入噪声干扰。第二,多跳依赖通常通过层叠消息传递隐式实现,不同阶次邻域信息被混合聚合,缺乏显式区分与可控建模。第三,大多数模型基于静态监督学习范式训练,决策机制在训练完成后趋于固定,难以根据学习过程的动态变化进行自适应调整,上述三个问题构成本文研究的核心出发点,后续章节将逐一提出针对性解决方案。

1.2.3 基于强化学习的决策优化方法

现有知识追踪模型大多基于监督学习范式进行训练,通过最小化预测误差来优化模型参数。然而,在真实学习场景中,学习者的知识状态、学习策略以及知识点间的作用关系均可能随时间发生演变。静态的监督学习范式在完成训练后,其决策机制趋于固定,难以根据学习过程中的动态变化进行自适应调整,这在一定程度上制约了模型对复杂学习过程的刻画能力。

强化学习作为一种通过与环境交互来学习最优决策策略的方法,为解决上述问题提供了新的思路。在强化学习框架下,智能体通过在环境中执行动作并接收奖励信号,逐步优化其决策策略以最大化长期回报。将这一思想引入知识追踪任务,可以将智能导学系统建模为环境,将知识追踪模型建模为智能体,通过奖励机制驱动模型根据学习者的实时表现动态调整预测策略。

尽管强化学习在推荐系统、对话系统等领域已有广泛应用,但在知识追踪领域的探索仍处于起步阶段。部分研究尝试将强化学习与知识追踪相结合,但主要集中在学习路径推荐、题目推荐等下游任务,较少直接应用于知识状态建模与作答预测任务。

近期研究开始关注强化学习在知识追踪核心任务中的应用。Tong 等人[56]提出了融合深度知识追踪和认知负荷估计的个性化学习路径生成方法,通过双流神经网络架构同时建模学生的知识状态和认知负荷水平,并使用双目标优化算法平衡知识获取与认知负荷管理。Wu 等人[57]提出了强化学习增强的图神经网络模型,将相对熵引入强化学习框架来优化知识追踪性能。

如何将强化学习框架与知识追踪的核心建模目标有机结合,仍是当前研究面临的重要挑战。未来研究需要进一步探索如何设计合适的奖励函数、状态表示和动作空间,使强化学习能够有效提升知识追踪模型对动态学习过程的自适应能力。

1.2.6 研究现状总结与本文定位

综上所述,现有知识追踪研究已从多个角度对知识状态建模进行了深入探索,在预测性能上取得了显著进展。然而,在复杂学习场景下,现有方法仍面临以下关键问题:

(1) 邻域信息质量区分不足。现有方法通常将邻域知识点视为同质节点进行更新,未能有效区分哪些邻居具有促进、不确定或干扰作用,可能引入噪声干扰,影响知识点表征质量与状态更新的准确性。

(2) 多跳依赖建模不充分。尽管已有研究引入图神经网络对知识结构进行建模,但其多跳依赖通常通过层叠消息传递隐式实现,不同阶的邻域信息在传播过程中往往被混合聚合,缺乏显式区分与可控建模。

(3) 静态建模范式适应性不足。大多数现有模型基于监督学习范式训练,其决策机制在训练完成后趋于固定,难以根据学习过程的动态变化进行自适应调整。

基于上述研究现状与存在问题,本文提出一种知识点强化表征驱动的知识追踪模型(Knowledge point Representation-Driven Knowledge Tracing, KRD-KT)。该模型聚焦于知识点强化表征与知识点相互作用建模这一核心问题,从结构化建模与决策机制两个层面进行系统改进。具体而言,本文通过引入三支决策理论对知识点邻域进行差异化划分,通过多阶邻域显式建模机制刻画多跳依赖的差异化

影响，并通过强化学习框架实现对动态学习过程的自适应建模，从而提升模型对复杂知识结构与动态学习过程的刻画能力。

1.3 本文的研究内容

针对现有知识追踪研究中存在的邻域信息质量区分不足、多跳依赖建模不充分以及静态建模范式适应性不足等问题，本文提出了一种知识点强化表征驱动的知识追踪模型（Knowledge point Representation-Driven Knowledge Tracing, KRD-KT）。该模型从知识点表征增强与动态决策优化两个层面展开研究，主要内容如下：

（1）基于三支决策的知识点邻域差异化建模

现有知识追踪模型在更新知识点状态时，通常将所有邻域知识点视为同质节点进行统一处理，缺乏对邻域信息质量的有效区分，可能引入噪声干扰。针对这一问题，本文引入三支决策理论，将目标知识点的邻域划分为正域、边界域和负域三个区域。正域包含与目标知识点高度相关的邻居，对状态更新具有积极促进作用；边界域包含相关性不确定的邻居，需要谨慎处理；负域包含低相关性邻居，可能对状态更新产生干扰。通过对三个区域采用差异化的信息传递策略，模型能够重点利用高质量邻域信息，弱化不确定信息，抑制噪声干扰，从而提升知识点表征的稳定性与鲁棒性。

（2）多阶邻域显式建模机制

现有基于图神经网络的知识追踪方法虽然能够建模知识点之间的结构关系，但其多跳依赖通常通过层叠消息传递隐式实现，导致不同阶数的邻域信息在传播过程中被混合聚合，缺乏显式区分与可控建模。针对这一局限，本文提出多阶邻域显式建模机制，通过显式分离一阶邻居和二阶邻居，并引入距离衰减权重来刻画不同阶数邻域对目标知识点的差异化影响。该机制基于“距离越远、影响越弱”的认知规律，通过指数衰减函数对远距离邻域的影响进行合理削弱，在引入深层依赖信息的同时有效抑制远邻噪声，使模型能够更准确地刻画知识点之间的多跳依赖关系。

（3）基于 Actor-Critic 的强化学习优化框架

大多数现有知识追踪模型基于监督学习范式训练，其决策机制在训练完成后趋于固定，难以根据学习过程的动态变化进行自适应调整。为提升模型对动态学习过程的刻画能力，本文引入强化学习框架，将智能导学系统（Intelligent Tutoring System, ITS）建模为环境，将知识追踪模型建模为智能体。模型采用 Actor-Critic 架构，其中价值网络（Critic）评估当前知识状态的价值并计算时间差分误差（TD 误差），策略网络（Actor）根据 TD 误差优化预测策略。通过与智能导学系统的实时交互，模型能够根据奖励信号动态调整其对学习者作答结果的预测，实现对条件概率分布的自适应建模，从而提升对动态学习过程的适应能力。

（4）模型有效性验证与分析

为全面评估所提模型的有效性，本文在多个真实教育数据集上进行了系统实验。首先，通过与多种经典及前沿知识追踪模型的对比实验，从预测准确性（AUC、ACC）和知识状态表示质量（DOA）等多个角度验证模型的优越性。其次，通过消融实验分析各关键模块（三支决策机制、多阶邻域建模、强化学习框架）对模型性能的贡献。再次，通过超参数敏感性分析探究关键参数（距离衰减系数、三支决策阈值、邻域阶数等）对模型性能的影响。最后，通过可视化分析和可解释性分析，展示模型对知识状态演化过程的建模能力，并为模型预测提供结构化解释，增强模型的透明度和可信度。

综上所述，本文围绕知识点强化表征与动态决策优化这一核心主题，从邻域质量筛选、多阶依赖建模和自适应优化三个方面对知识追踪模型进行系统改进，力求在提升预测性能的同时增强模型的鲁棒性与自适应能力。

1.4 本文的组织结构

本文共分为五章，各章节的组织结构如下：

第 1 章 绪论。本章首先阐述知识追踪研究的背景与意义，说明在线教育快速发展背景下知识追踪技术的重要性，以及现有方法面临的主要挑战。其次，系统综述国内外知识追踪研究现状，从基于深度学习的方法、基于图神经网络的方法以及基于强化学习的方法三个方面进行分类梳理，分析现有研究的优势与不足，归纳现有方法存在的三个主要问题。然后，明确本文的研究内容，包括基于三支决策的邻域差异化建模、多阶邻域显式建模机制、基于 Actor-Critic 的强化学习优化框架以及模型有效性验证等四个方面。最后，介绍本文的组织结构安排。

第 2 章 相关理论基础。本章系统介绍本文研究所涉及的理论基础与关键技术。首先介绍知识追踪的基本概念、任务定义和发展历程，阐明知识追踪在教育系统中的作用。其次介绍注意力机制的基本原理及其在序列建模中的应用。再次介绍图神经网络的基本框架，包括消息传递机制、信息聚合方法等核心内容。然后介绍强化学习的基本概念，包括马尔可夫决策过程、价值函数、策略优化以及 Actor-Critic 方法等。最后介绍三支决策理论的基本思想、决策规则以及在不确定性信息处理中的应用。这些理论基础为后续模型设计提供了必要的理论支撑。

第 3 章 知识点强化表征驱动的知识追踪模型。本章详细阐述所提 KRD-KT 模型的设计思想、问题定义、模型架构以及训练方法。首先阐述模型提出的思想与动机，说明引入三支决策、多阶邻域建模和强化学习的必要性。其次给出问题的形式化定义，包括题目表示、状态定义、动作空间、奖励机制等关键要素。然后详细介绍模型架构，包括基础网络、价值网络和策略网络三个核心组件。在基

础网络部分，重点阐述知识点表示图的构建、题目增强机制、基于三支决策的多阶邻域建模方法、差异化信息传递策略以及层次化信息聚合过程。在价值网络和策略网络部分，详细说明状态价值评估和动作策略优化的实现方式。最后给出基于 Actor-Critic 的模型训练算法，明确参数更新规则和训练流程。

第 4 章 实验。本章通过系统实验验证所提模型的有效性。首先介绍实验所使用的数据集，包括 ASSISTments2009、Junyi Academy 和 EdNet 三个公开数据集的基本信息、统计特征和预处理方法。其次介绍数据集划分策略和实验环境配置。然后介绍对比模型的选择依据和评估指标的定义，包括预测性能指标（AUC、ACC）和知识状态表示质量指标（DOA）。接下来通过预测性能对比实验验证模型的预测准确性，通过知识状态表示质量对比实验验证模型内部表示的可信程度。进一步地，通过超参数敏感性分析探究关键参数对模型性能的影响规律，通过消融实验验证各关键模块的有效性。最后，通过可视化分析展示模型对知识状态演化过程的建模能力。实验结果表明，所提模型在预测性能、表示质量和稳定性等方面均优于对比模型。

第 5 章 总结与展望。本章对全文工作进行总结，并对未来研究方向进行展望。首先总结本文的主要研究工作和创新点，包括基于三支决策的邻域差异化建模、多阶邻域显式建模机制、基于 Actor-Critic 的强化学习优化框架以及系统的实验验证。然后总结实验结果，说明所提模型在多个数据集上取得的性能提升以及各模块的有效性。最后展望未来研究方向，包括知识结构的扩展、学习行为信息的深度融合、多模态数据的引入、模型效率的优化以及在更多实际教学场景中的应用等，为后续研究提供参考。

通过上述组织安排，本文从理论基础、模型设计到实验验证形成了完整的研究体系，力求系统、全面地阐述知识点强化表征驱动的知识追踪模型的设计思想、技术方法和应用效果。

第2章 相关理论基础

2.1 知识追踪

知识追踪（Knowledge Tracing, KT）是智能教育系统中的核心技术，旨在通过分析学习者的交互数据，动态追踪其对不同知识点的掌握程度，并预测未来的学习表现。准确的知识追踪是实现个性化教学的关键前提。

2.1.1 知识追踪的基本概念

知识追踪的核心任务是根据学习者的历史学习行为序列，建模其知识状态，并预测在未来题目上的作答表现。从技术角度来看，这是一个典型的序列预测问题，面临三大挑战：学习者的知识状态是不可直接观测的隐变量，只能通过作答结果间接推断；知识点之间存在复杂的依赖关系；学习是一个动态演化过程，知识状态会随练习进行而变化。

形式化地，给定学习者集合 $U = \{u_1, u_2, \dots, u_n\}$ ，题目集合 $E = \{e_1, e_2, \dots, e_m\}$ ，知识点集合 $C = \{c_1, c_2, \dots, c_k\}$ 。学习者在时刻 t 的交互记录表示为三元组 $x_t = (e_t, c_t, r_t)$ ，其中 e_t 是题目， c_t 是相关知识点集合， $r_t \in \{0, 1\}$ 是作答结果。知识追踪任务定义为：给定历史交互序列 $X_{1:t} = \{x_1, x_2, \dots, x_t\}$ 和题目 e_{t+1} ，预测作答结果：

$$P(r_{t+1} = 1 | X_{1:t}, e_{t+1})$$

通过引入知识状态 h_t ，问题可分解为知识状态更新 $h_t = f(X_{1:t})$ 和作答预测 $P(r_{t+1} | h_t, e_{t+1}) = g(h_t, e_{t+1})$ 。不同模型通过设计不同的 $f(\cdot)$ 和 $g(\cdot)$ 来实现建模。

图 2-1 展示了知识追踪的基本过程。



图 2-1 知识追踪过程图

Fig 2-1 Knowledge tracing process map

2.1.2 传统知识追踪方法

贝叶斯知识追踪（BKT）是最早被广泛应用的知识追踪模型，基于隐马尔可夫模型将知识掌握状态建模为“已掌握”或“未掌握”二值变量[58]。BKT 包含四个参数：初始掌握概率 $P(L_0)$ 、学习转移概率 $P(T)$ 、失误概率 $P(S)$ 和猜测概率 $P(G)$ 。其优势在于参数具有明确的教育学解释，但二值状态假设过于简化，且假设知识点相互独立，难以捕捉复杂学习模式。

项目反应理论（IRT）通过建立学习者能力 θ 与题目难度 b 的函数关系来预测作答：

$$P(r = 1 | \theta, a, b) = \frac{1}{1 + \exp(-a(\theta - b))}$$

其中 a 是区分度参数。IRT 在标准化测试中应用广泛，但假设能力在测试过程中保持不变，无法刻画动态演化过程。

2.1.3 基于深度学习的知识追踪方法

深度知识追踪（DKT）首次将循环神经网络应用于知识追踪任务[59]。DKT 使用 LSTM 对交互序列建模，在每个时间步 t ，输入为 (e_t, r_t) ，LSTM 更新隐状态 $h_t = \text{LSTM}(x_t, h_{t-1})$ ，然后预测下一时刻各知识点的掌握概率 $\hat{y}_{t+1} = \text{sigmoid}(W \cdot h_t + b)$ 。

DKT 能够自动学习知识状态的分布式表示，在预测性能上显著优于传统方法。然而，模型缺乏可解释性，对长序列的建模能力有限，且未显式建模知识点之间的结构关系。后续研究提出了多种改进：Zhang 等人提出动态键值记忆网络（DKVMN），通过外部记忆机制增强长期依赖建模能力；Pandey 等人提出自注意力知识追踪模型（SAKT），通过自注意力机制捕捉序列中任意位置的依赖关系。

为更好地建模知识点结构，研究者引入图神经网络（GNN）增强知识追踪。Nakagawa 等人提出的 GKT 模型[60]使用图卷积网络对知识点关系图建模，通过消息传递使知识点表示融合邻域信息：

$$h_{c_i}^{(l+1)} = \sigma \left(W^{(l)} \cdot \text{AGG} \left(\{h_{c_j}^{(l)} : c_j \in N(c_i)\} \right) \right)$$

基于 GNN 的方法能够显式建模知识点依赖关系，但仍面临挑战邻域知识点被视为同质节点更新，未能有效区分不同质量的邻域信息；多跳依赖通过层叠消息传递隐式实现，不同阶数邻域信息被混合聚合，缺乏显式区分。这些问题为本文研究提供了改进方向。

2.1.4 知识追踪的应用

知识追踪在智能教育系统中发挥重要作用。基于知识状态评估，系统可为不同学习者推荐个性化学习路径；实时监测知识状态变化，及时发现薄弱环节并进行干预；评估整体教学效果，为教学改进提供依据；在自适应测试中根据答题表现动态调整题目难度。

2.1.5 本节小结

本节介绍了知识追踪的基本概念和发展历程。传统方法如 BKT 和 IRT 虽然可解释性好，但表达能力有限。深度学习方法通过神经网络自动学习知识状态表示，性能显著提升，但在知识结构建模和自适应能力方面仍有不足。这些挑战为本文研究提供了方向。

2.2 注意力机制

注意力机制（Attention Mechanism）是深度学习领域的重要创新，其核心思想源于人类的选择性注意能力。注意力机制使模型能够自适应地关注输入序列中的重要信息，从而提升对复杂任务的建模能力。

2.2.1 注意力机制的基本原理

注意力机制最早在机器翻译任务中提出，用于解决序列到序列模型的信息瓶颈问题[61]。传统编码器-解码器架构将整个输入序列压缩为固定长度的向量，导致信息丢失。注意力机制通过动态加权机制，允许解码器在生成每个输出时选择性关注输入的不同部分。

从数学角度看，注意力机制本质是加权求和过程。给定查询向量（Query） q 、键向量集合（Keys） $\{k_1, k_2, \dots, k_n\}$ 和值向量集合（Values） $\{v_1, v_2, \dots, v_n\}$ ，注意力机制计算相关性得分，归一化为权重，然后加权求和：

$$\text{Attention}(q, K, V) = \sum_{i=1}^n \alpha_i v_i$$

其中注意力权重为：

$$\alpha_i = \frac{\exp(s(q, k_i))}{\sum_{j=1}^n \exp(s(q, k_j))}$$

评分函数 $s(q, k_i)$ 衡量查询与键的相关性。常见的有点积注意力 $s(q, k_i) = q^T k_i$ 和缩放点积注意力 $s(q, k_i) = \frac{q^T k_i}{\sqrt{d_k}}$ ，缩放因子 $\sqrt{d_k}$ 可防止点积过大导致的梯度消失。

2.2.2 自注意力与多头注意力机制

自注意力机制（Self-Attention）是注意力的重要变体，其特点是查询、键和值均来自同一输入序列，在序列内部建立元素依赖关系[62]。给定输入序列 $X = [x_1, x_2, \dots, x_n]$ ，通过线性变换得到 $Q = XW^Q$ ， $K = XW^K$ ， $V = XW^V$ ，然后计算：

$$\text{SelfAttention}(X) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 QK^T 是 $n \times n$ 的注意力矩阵，第 (i, j) 元素表示位置 i 对位置 j 的关注程度。自注意力能够并行计算所有位置的表示，并直接捕捉任意距离的依赖关系。

多头注意力机制（Multi-Head Attention）并行运行多个注意力头来捕捉不同方面的信息。第 i 个头计算为：

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

最终输出通过拼接所有头并线性变换：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

不同注意力头可学习到输入序列的不同依赖模式，如某些头关注语法依赖，另一些关注语义关联，提升了模型的表达能力。

2.2.3 注意力机制在知识追踪中的应用

自注意力知识追踪（SAKT）首个将自注意力引入知识追踪[63]。SAKT 使用自注意力建模历史交互序列，允许当前预测直接依赖于历史任意时刻的交互。通过多层自注意力提取序列依赖关系，基于增强表示预测下一题目的作答概率。

SAKT 的优势在于能够捕捉全局依赖关系，无需像 RNN 那样递归传播信息。注意力权重提供了可解释性，可通过可视化了解模型参考了哪些历史交互。后续研究进一步探索了注意力在知识追踪中的应用，如结合多头注意力关注知识点的不同类型依赖，引入时间信息或因果约束建模时序特性。

相比循环神经网络，基于注意力的知识追踪模型具有并行处理效率高、长距离依赖建模能力强、提供可解释性等优势。然而，注意力机制主要关注时序依赖关系，对知识点之间的结构化关系建模仍然不足，这为后续研究提供了改进方向。

2.2.4 本节小结

本节介绍了注意力机制的基本原理及其在知识追踪中的应用。注意力机制通过自适应分配权重使模型聚焦相关信息。自注意力允许序列内部元素相互关注，能够有效捕捉长距离依赖。多头注意力通过并行运行多个头从不同角度理解输入。在知识追踪任务中，注意力机制相比 RNN 具有更强的依赖建模能力和计算效率，已成为现代知识追踪模型的重要组件。

2.3 图神经网络

图神经网络（Graph Neural Network, GNN）是专门用于处理图结构数据的深度学习模型。现实世界中许多数据具有图结构，如社交网络、知识图谱、分子结构等。图神经网络通过在图结构上定义神经网络操作，有效捕捉节点之间的依赖关系和拓扑结构信息。

2.3.1 图的基本概念

图可形式化定义为，其中 $V = \{v_1, v_2, \dots, v_N\}$ 是节点集合， $E \subseteq V \times V$ 是边集合。根据边的方向性，图分为无向图和有向图。

图的结构用邻接矩阵 $A \in \mathbb{R}^{N \times N}$ 表示, $A_{ij} = 1$ 表示节点 v_i 和 v_j 间存在边。节点特征用特征矩阵 $X \in \mathbb{R}^{N \times d}$ 表示, 第 i 行 x_i 是节点 v_i 的特征向量。节点 v_i 的邻居集合定义为 $N(v_i) = \{v_j : (v_i, v_j) \in E\}$ 。

图神经网络的目标是通过聚合邻域信息和自身特征, 学习包含图结构和节点特征的节点表示。

2.3.2 消息传递框架

图神经网络的核心是消息传递 (Message Passing) 机制[6]。在第 l 层, 节点表示更新分为消息聚合和节点更新两步:

$$m_{v_i}^{(l+1)} = \text{AGGREGATE}^{(l)} \left(\left\{ h_{v_j}^{(l)} : v_j \in N(v_i) \right\} \right)$$

$$h_{v_i}^{(l+1)} = \text{UPDATE}^{(l)} \left(h_{v_i}^{(l)}, m_{v_i}^{(l+1)} \right)$$

其中 $h_{v_i}^{(l)}$ 是节点 v_i 在第 l 层的表示, $m_{v_i}^{(l+1)}$ 是聚合的邻居消息。常见聚合函数包括求和、均值、最大值等。通过堆叠多层, 节点表示能融合 K 跳邻域信息, 捕捉多跳依赖关系。

2.3.3 图卷积网络

图卷积网络 (GCN) 将卷积操作推广到图结构[65]。GCN 的传播规则为:

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right)$$

其中 $\tilde{A} = A + I$ 是添加自环的邻接矩阵, $\tilde{D}$ 是度矩阵, $W^{(l)}$ 是权重矩阵。从节点级别看, 节点 v_i 的更新为:

$$h_{v_i}^{(l+1)} = \sigma \left(\sum_{v_j \in N(v_i) \cup \{v_i\}} \frac{1}{\sqrt{\tilde{D}_{ii}} \sqrt{\tilde{D}_{jj}}} h_{v_j}^{(l)} W^{(l)} \right)$$

对称归一化系数 $\frac{1}{\sqrt{\tilde{D}_{ii}} \sqrt{\tilde{D}_{jj}}}$ 平衡了不同度数节点的影响。GCN 通过矩阵运算高效并行更新所有节点表示, 具有良好的局部性和参数共享性质。

2.3.4 图注意力网络

图注意力网络 (GAT) 引入注意力机制动态计算邻居重要性[66]。节点 v_i 对邻居 v_j 的注意力系数通过以下方式计算:

$$e_{ij} = \text{LeakyReLU} \left(\tilde{a}^T \left[W h_{v_i} \parallel W h_{v_j} \right] \right)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{v_k \in N(v_i)} \exp(e_{ik})}$$

节点更新为:

$$h_{v_i}^{(l+1)} = \sigma \left(\sum_{v_j \in N(v_i)} \alpha_{ij} W h_{v_j}^{(l)} \right)$$

GAT 通常采用多头注意力，并行运行 K 个独立头后拼接或平均输出。GAT 能为不同邻居分配自适应权重，在邻居重要性不均的图上特别有效，且注意力权重提供了可解释性。

2.3.5 图神经网络在知识追踪中的应用

图神经网络为知识追踪提供了显式建模知识点结构关系的方式。知识点可表示为图中节点，知识点间的先修、相似等关系表示为边。通过图神经网络的消息传递，知识点表示能融合相关知识点信息。

基于图的知识追踪模型（GKT）将知识点建模为图节点，通过图卷积学习知识点表示[67]。在学习者与题目交互后，GKT 根据作答结果更新相关知识点状态，并通过图卷积将信息传播到邻居知识点，体现知识迁移规律。

后续研究引入图注意力机制为邻居分配自适应权重，构建异构图建模多种实体关系，探索动态图神经网络使关系随学习过程演化。

然而，现有方法仍面临挑战：邻域知识点被视为同质节点更新，未能有效区分不同质量的邻域信息，可能引入噪声；多跳依赖通过层叠消息传递隐式实现，不同阶数邻域信息被混合聚合，缺乏显式区分。这些问题为本文研究提供了改进方向，后续章节将介绍如何通过三支决策和多阶邻域显式建模来解决这些问题。

2.3.6 本节小结

本节介绍了图神经网络的基本原理及其在知识追踪中的应用。图神经网络通过消息传递在图结构上传播和聚合信息，有效捕捉节点依赖关系和拓扑结构。图卷积网络通过归一化邻域聚合实现高效图卷积，图注意力网络通过注意力机制为不同邻居分配自适应权重。在知识追踪中，图神经网络能显式建模知识点结构关系，但在多跳依赖显式建模和邻域信息质量区分方面仍有不足。

2.4 强化学习

强化学习（Reinforcement Learning, RL）是机器学习的一个重要分支，通过智能体与环境的交互来学习最优策略。与监督学习和无监督学习不同，强化学习强调通过试错（Trial-and-Error）机制在动态环境中做出决策，通过最大化累积奖励来学习行为策略。强化学习在游戏、机器人控制、推荐系统等领域取得了显著成功，近年来也被引入知识追踪任务，用于建模学习过程中的序贯决策问题。本节将介绍强化学习的基本概念、核心算法以及在知识追踪中的应用。

2.4.1 强化学习的基本概念

强化学习问题通常使用马尔可夫决策过程（Markov Decision Process, MDP）进行形式化描述。一个 MDP 可以表示为五元组 (S, A, P, R, γ) ，其中： S 是状态空

间，表示环境的所有可能状态； A 是动作空间，表示智能体可以执行的所有动作； $P: S \times A \times S \rightarrow [0,1]$ 是状态转移概率函数， $P(s'|s,a)$ 表示在状态 s 执行动作 a 后转移到状态 s' 的概率； $R: S \times A \rightarrow \mathbb{R}$ 是奖励函数， $R(s,a)$ 表示在状态 s 执行动作 a 获得的即时奖励； $\gamma \in [0,1]$ 是折扣因子，用于平衡即时奖励和长期奖励的重要性。

在每个时间步 t ，智能体观察当前状态 s_t ，根据策略 π 选择动作 a_t ，执行动作后获得奖励 r_t 并转移到新状态 s_{t+1} 。策略 $\pi: S \rightarrow A$ 定义了智能体的行为模式，可以是确定性策略（给定状态输出确定动作）或随机性策略（给定状态输出动作的概率分布）。强化学习的目标是找到最优策略 π^* ，使得从任意初始状态出发的期望累积奖励最大化：

$$\pi^* = \arg \max_{\pi} E \left[\sum_{t=0}^{\infty} \gamma^t r_t / \pi \right]$$

为了评估策略的好坏，强化学习引入了价值函数的概念。状态价值函数 $V^{\pi}(s)$ 表示在状态 s 开始，遵循策略 π 所能获得的期望累积奖励：

$$V^{\pi}(s) = E_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t / s_0 = s \right]$$

动作价值函数（Q 函数） $Q^{\pi}(s,a)$ 表示在状态 s 执行动作 a ，之后遵循策略 π 所能获得的期望累积奖励：

$$Q^{\pi}(s,a) = E_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t / s_0 = s, a_0 = a \right]$$

最优价值函数定义为所有策略下的最大价值： $V^*(s) = \max_{\pi} V^{\pi}(s)$ 和 $Q^*(s,a) = \max_{\pi} Q^{\pi}(s,a)$ 。通过贝尔曼最优性方程（Bellman Optimality Equation），最优 Q 函数满足：

$$Q^*(s,a) = R(s,a) + \gamma \sum_{s' \in S} P(s'|s,a) \max_{a'} Q^*(s',a')$$

一旦获得了最优 Q 函数，最优策略可以通过贪婪策略得到： $\pi^*(s) = \arg \max_a Q^*(s,a)$ 。

图 2-2 展示了强化学习的基本框架和智能体与环境的交互过程。




图 2-2 强化学习智能体与环境交互图

2.4.2 主要强化学习算法

强化学习算法可以分为基于价值的方法、基于策略的方法和演员-评论家方法。基于价值的方法通过学习价值函数来间接获得策略，最经典的算法是 Q-learning。Q-learning 通过时序差分（Temporal Difference, TD）学习来迭代更新 Q 函数：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)]$$

其中， α 是学习率， $r_t + \gamma \max_{a'} Q(s_{t+1}, a')$ 是 TD 目标， $r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)$ 是 TD 误差。Q-learning 是一种离策略（Off-policy）算法，可以使用任意行为策略收集的数据来学习最优策略。

深度 Q 网络（Deep Q-Network, DQN）将 Q-learning 与深度神经网络结合，使用神经网络 $Q(s, a; \theta)$ 来近似 Q 函数[68]。DQN 的损失函数定义为：

$$L(\theta) = E \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right]$$

其中， θ^- 是目标网络的参数，定期从当前网络复制以稳定训练。DQN 还引入了经验回放（Experience Replay）机制，将历史交互数据存储在缓冲区中，通过随机采样来打破数据相关性，提高学习效率。

基于策略的方法直接学习策略函数，而不需要显式维护价值函数。策略梯度（Policy Gradient）方法通过梯度上升优化策略参数，使期望累积奖励最大化。策略参数的梯度可以表示为：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) Q^{\pi_{\theta}}(s, a)]$$

其中， $\pi_{\theta}(a|s)$ 是参数化的策略， $J(\theta)$ 是期望累积奖励。实际应用中，Q 值通常用累积奖励的估计或优势函数替代。策略梯度方法的优势在于可以直接优化随机性策略，适合处理连续动作空间和高维状态空间。

演员-评论家（Actor-Critic）方法结合了价值方法和策略方法的优势[69]。该方法维护两个网络：演员（Actor）网络参数化策略 $\pi_{\theta}(a|s)$ ，负责选择动作；评论家（Critic）网络学习价值函数 $V_{\phi}(s)$ 或 $Q_{\phi}(s, a)$ ，负责评估动作的好坏。演员网络使用评论家提供的评估信号来更新策略，评论家网络则通过 TD 学习更新价值函数。优势演员-评论家（Advantage Actor-Critic, A2C）使用优势函数 $A(s, a) = Q(s, a) - V(s)$ 来减小梯度估计的方差。演员网络的更新为：

$$\nabla_{\theta} J(\theta) = \mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(a|s) A_{\phi}(s, a)]$$

评论家网络通过最小化 TD 误差来更新。Actor-Critic 方法兼具样本效率和策略优化的直接性，在许多任务中表现出色。

2.4.3 强化学习在知识追踪中的应用

强化学习为知识追踪任务提供了一种序贯决策的建模视角。在传统知识追踪方法中，模型仅被动地根据历史交互预测未来表现，而基于强化学习的方法将学习过程视为智能体与环境的交互过程，通过优化长期学习目标来主动调整知识状态的更新策略。

在知识追踪的强化学习建模中，状态通常定义为学习者当前的知识状态，动作可以是知识状态的更新方式或题目推荐策略，奖励则反映学习者的学习效果（如作答正确性、知识掌握程度的提升等）。通过强化学习框架，模型可以学习到如何根据学习者的当前状态和历史表现来最优地更新知识状态表示，使得长期预测性能最大化。

一些研究将深度强化学习引入知识追踪任务。例如，有研究使用 DQN 来学习知识点表示的更新策略，通过定义适当的奖励函数（如预测准确性）来指导模型学习。也有研究使用 Actor-Critic 框架，其中 Actor 网络负责生成知识状态更新策略，Critic 网络评估该策略对长期预测性能的影响[70]。这种建模方式使得知识状态更新不再是简单的前向传播，而是一个优化导向的决策过程。

强化学习在知识追踪中的应用还体现在自适应学习路径推荐上。通过将题目推荐建模为序贯决策问题，强化学习算法可以学习到个性化的题目推荐策略

[71], 根据学习者的实时状态动态调整推荐内容, 最大化学习者的长期学习收益。这种主动学习的思想与传统的被动预测形成了鲜明对比。

然而, 将强化学习应用于知识追踪也面临一些挑战。首先, 奖励函数的设计较为困难, 学习效果的评估往往具有延迟性和不确定性。其次, 状态空间和动作空间可能非常庞大, 给策略学习带来困难。再次, 离线学习场景中缺乏与环境的实时交互, 难以充分利用强化学习的探索机制。这些问题为本文的研究提供了改进方向, 后续章节将介绍如何设计适合知识追踪任务的强化学习框架。

2.4.4 本节小结

本节系统介绍了强化学习的基本概念和主要算法。强化学习通过智能体与环境的交互来学习最优决策策略, 使用马尔可夫决策过程进行形式化建模。基于价值的方法如 Q-learning 通过学习价值函数来间接获得策略, 基于策略的方法如策略梯度直接优化策略参数, Actor-Critic 方法则结合了两者的优势。在知识追踪任务中, 强化学习提供了一种序贯决策的建模视角, 可以主动优化知识状态更新策略和学习路径推荐。然而, 奖励设计、状态空间复杂性等问题仍需进一步研究。后续章节将介绍如何在三支决策和多阶邻域建模的基础上引入强化学习框架, 构建自适应的知识追踪模型。

2.5 三支决策

三支决策 (Three-Way Decision, TWD) 理论是基于粗糙集理论发展的决策框架, 通过将决策空间划分为接受、拒绝和延迟决策三个区域, 引入不确定性区域来处理决策中的模糊性和不完全信息。与传统二值决策不同, 三支决策允许在证据不充分时延迟决策或采取保守策略, 从而提高决策的稳健性。

2.5.1 三支决策的基本思想

在现实决策场景中, 决策者往往面临信息不完全、知识不确定的情况。传统的二值决策 (如是/否、接受/拒绝) 要求在两个选项中做出明确选择, 但在信息不足时, 强制性的二值决策可能导致错误。三支决策通过引入第三种选项——延迟决策或边界决策, 提供了更灵活的决策框架[1]。

三支决策的核心思想可通过医学诊断理解。在诊断患者是否患病时, 如果症状明显、检查确凿, 医生可做出确诊 (接受) 或排除 (拒绝); 但如果症状模糊、检查结果不一致, 医生可选择进一步观察、增加检查 (延迟决策), 而不是冒险做出可能错误的诊断。

在数学上, 三支决策将论域 U 中的对象划分为三个不相交的区域: 正域 $POS(C)$ 、负域 $NEG(C)$ 和边界域 $BND(C)$ 。对于给定概念 C , 这三个区域满足:

$$POS(C) \cup BND(C) \cup NEG(C) = U$$

$$POS(C) \cap BND(C) = \emptyset, POS(C) \cap NEG(C) = \emptyset, BND(C) \cap NEG(C) = \emptyset$$

正域中的对象可确定地分类为属于概念 C ，负域中的对象可确定地分类为不属于 C ，边界域中的对象因证据不足而无法做出确定分类。

2.5.2 基于概率的三支决策

三支决策与概率粗糙集密切相关。在概率粗糙集框架下，三个决策区域通过条件概率和阈值参数定义[2]。给定论域 U 上的等价关系 R ，对于对象 $x \in U$ ，其等价类 $[x]_R$ 表示与 x 在关系 R 下等价的所有对象集合。对于概念 $C \subseteq U$ ，对象 x 属于 C 的条件概率定义为：

$$P(C|[x]_R) = \frac{|C \cap [x]_R|}{|[x]_R|}$$

引入两个阈值参数 α 和 β ，满足 $0 \leq \beta < \alpha \leq 1$ ，三个决策区域定义为：

$$\text{POS}_{\alpha,\beta}(C) = \{x \in U : P(C|[x]_R) \geq \alpha\}$$

$$\text{BND}_{\alpha,\beta}(C) = \{x \in U : \beta < P(C|[x]_R) < \alpha\}$$

$$\text{NEG}_{\alpha,\beta}(C) = \{x \in U : P(C|[x]_R) \leq \beta\}$$

参数 α 称为接受阈值，只有当条件概率达到或超过 α 时，才确定地将对象分类为属于 C 。参数 β 称为拒绝阈值，只有当条件概率低于或等于 β 时，才确定地将对象分类为不属于 C 。当条件概率处于 (β, α) 之间时，对象被划入边界域。

阈值参数的选择直接影响三个区域的大小和决策的保守程度。在实际应用中，这两个参数可以根据任务需求手动设置，也可以通过交叉验证等数据驱动方法确定，还可以作为模型的可学习参数通过训练优化。

图 2-3 展示了三支决策的三区域划分。




图 2-3：三支决策的三区域划分

2.5.3 三支决策在知识追踪中的应用

三支决策为知识追踪任务提供了处理不确定性的新视角。在基于图神经网络的知识追踪模型中，三支决策可以用于邻域信息的质量评估和筛选。对于目标知识点，其邻居知识点的影响可能存在差异：某些邻居与目标知识点高度相关，其

信息应该被充分利用；某些邻居相关性较弱，其信息可能引入噪声；还有一些邻居的影响不确定，需要谨慎对待。

具体而言，在图神经网络的消息传递过程中，可以计算目标知识点 c_i 与邻居知识点 c_j 之间的相关性或相似度 s_{ij} 。基于三支决策框架，根据相关性与阈值 α 、 β 的关系，将邻居划分为三类：

当 $s_{ij} \geq \alpha$ 时，邻居 c_j 属于正域，是高质量邻居，应该赋予较大的聚合权重，充分利用其信息。当 $s_{ij} \leq \beta$ 时，邻居 c_j 属于负域，是低质量邻居，应该赋予较小的权重或直接排除，避免噪声干扰。当 $\beta < s_{ij} < \alpha$ 时，邻居 c_j 属于边界域，其影响不确定，应该采取保守策略，如赋予中等权重或延迟决策。

通过这种三分机制，模型能够自适应地筛选和加权邻域信息，提高知识状态更新的准确性和鲁棒性。相比传统的均等对待所有邻居或仅基于注意力机制的方法，三支决策提供了更明确的决策边界和更灵活的处理策略。

2.5.4 本节小结

本节介绍了三支决策理论的基本概念和应用。三支决策通过将决策空间划分为接受、拒绝和延迟三个区域，为处理不确定性决策提供了灵活框架。基于概率的三支决策通过条件概率和阈值参数定义三个决策区域。在知识追踪任务中，三支决策可应用于邻域信息筛选，为知识点邻域的差异化建模提供了理论支撑。

2.6 本章小结

本章系统介绍了与本文研究相关的理论基础和关键技术，为后续章节提出的知识点强化表征驱动的知识追踪模型（KRD-KT）奠定了理论基础。

首先，本章介绍了知识追踪的基本概念和发展历程。传统方法如贝叶斯知识追踪和项目反应理论虽然具有良好的可解释性，但表达能力有限。深度学习方法通过神经网络自动学习知识状态表示，在预测性能上取得了显著进展，但在知识结构建模和自适应能力方面仍存在不足。

其次，本章介绍了注意力机制的基本原理及其变体。自注意力机制和多头注意力机制在捕捉长距离依赖关系方面表现出色，已被广泛应用于知识追踪任务。然而，现有方法主要关注时序依赖关系，对知识点之间的结构化关系建模仍然不足。

再次，本章介绍了图神经网络的基本概念和主要方法。图神经网络通过消息传递机制能够显式建模知识点之间的结构关系，但现有方法在多跳依赖的显式建模和邻域信息质量区分方面仍有不足，为本文三支决策和多阶邻域建模的提出提供了改进方向。

然后，本章介绍了三支决策理论的基本思想和数学框架。三支决策通过引入边界域处理不确定性，为知识追踪中邻域信息的差异化筛选提供了理论支撑。

最后，本章介绍了强化学习的基本框架和主要算法。Actor-Critic 方法将策略优化与价值估计相结合，为知识追踪提供了序贯决策的建模视角，是本文模型的核心算法框架。

综合上述理论基础，本文后续章节将提出知识点强化表征驱动的知识追踪模型（KRD-KT），通过三支决策的邻域差异化划分、多阶邻域显式建模机制和强化学习自适应优化框架，构建更加准确和稳健的知识追踪系统。

第3章 知识点强化表征驱动的知识追踪模型

3.1 模型思想与问题提出

3.1.1 模型提出的思想

当前研究一般默认知识追踪模型与智能导学系统互相交互，智能导学系统为知识追踪模型提供诸如当前时刻练习题目、历史练习题目及作答结果等各类数据。知识追踪模型基于这些数据，使用多种方法增强知识点的表示，从而建模作答结果在题目信息约束下的概率分布，已取得了较好的结果。然而，在与智能导学系统的交互方面，现存的模型在自适应题目数据分布的动态变化方面仍然存在较大挑战。具体地，目前的知识追踪模型在完成训练后就建模了静态的分布，当题目信息发生动态变化时模型的预测效果必然下降。

为了使知识追踪模型具备建模动态概率分布的能力，本文引入强化学习范式，假设智能导学系统为知识追踪模型所在的环境，智能导学系统提供的各类数据为状态，提出的知识点强化表征驱动的知识追踪模型 **KRD-KT** 为智能体，**KRD-KT** 给出的动作是预测学习者会作答正确还是错误。智能导学系统根据 **KRD-KT** 的动作对其进行奖励，驱动 **KRD-KT** 调整动作预测得更加准确，以获得更大的奖励。通过这一机制，模型能够根据智能导学系统在每个时间步的反馈动态调整知识状态表示，从而克服监督学习范式下静态建模的局限。

然而，强化学习框架能够有效工作的前提，是模型对知识点的表征质量足够准确。知识点表征的优劣直接决定了状态的表达能力，进而影响智能体动作决策的准确性与奖励信号的有效性。因此，如何在强化学习框架下构建高质量的知识点的表征，是本文需要解决的核心问题。

在基于图神经网络的知识点的表征方法中，现有研究普遍将目标知识点的所有邻域节点视为同质信息进行统一聚合，忽视了邻域知识点对目标知识点影响的差异性。具体而言，与目标知识点高度相关的邻居能够提供有益的结构化信息，应当得到充分利用；相关性较弱的邻居可能引入噪声干扰，应当加以抑制；而相关性处于中间状态的邻居，其影响具有不确定性，需要采取保守策略谨慎对待。这种同质化聚合方式不仅无法有效区分邻域信息的质量，还会导致低质量信息污染知识点的表征，最终影响模型在强化学习框架下的预测性能。

此外，现有方法通过层叠多层图卷积隐式捕捉多跳依赖，不同阶次的邻域信息在传播过程中被混合聚合，难以显式区分一阶邻域与二阶邻域对目标知识点的差异化影响。

针对上述问题，本文引入三支决策理论对图神经网络的邻域聚合过程进行改进。三支决策通过设定阈值参数 α 和 β ，将邻域知识点按相似度显式划分为正域、边界域和负域三类，分别对应高相关、不确定和低相关三种邻域关系，并对

三类邻域采用差异化的信息传递策略。在此基础上，本文进一步设计多阶邻域显式建模机制，对一阶和二阶邻域分层建模，通过层次化融合获得更具判别力的知识点表征，从而为强化学习框架提供高质量的状态表示，提升模型对动态学习过程的自适应建模能力。

3.1.2 问题的提出

智能导学系统为知识追踪模型提供学习者练习的题目，具体定义如下：

学习者练习的题目集合设为 $\mathcal{Q}$ ，其中第 i 个题目的独热编码可以表示为 $q_i \in 0,1^{|\mathcal{Q}|}$ ，1 位于第 i 个位置。

在时刻 t ，智能导学系统从上述题目集合中抽取题目用于学习者练习，记为 q_t 。设置题目嵌入矩阵 $\mathbf{E}_{\mathcal{Q}} \in \mathbb{R}^{|\mathcal{Q}| \times d_c}$ ，将题目的独热编码映射为分布式向量，如下：

$$\mathbf{q}_t = q_t \mathbf{E}_{\mathcal{Q}} \quad (0-1)$$

其中， $\mathbf{q}_t \in \mathbb{R}^{d_c}$ 是题目的分布式向量表示， d_c 是题目嵌入向量的维度。

3.1.3 问题定义

具体地，在每个离散时间步 t ，智能导学系统给出拟作答的题目 q_t ，记为状态 $s_t = q_t$ ；提出的知识追踪模型给出动作 $a_t \in 0,1$ ，表示时刻 t 模型预测的学习者作答结果， $a_t = 0$ 表示模型预测学习者会作答错误， $a_t = 1$ 表示模型预测学习者会作答正确；环境根据 a_t 给出奖励 r_t 和下一时间步的状态 s_{t+1} 。

智能导学系统根据 KRD-KT 的预测结果与学习者实际答题结果的一致性给出奖励，二者相同时奖励值为1，二者不同时奖励值为0。具体地，时刻 t 的奖励值记为 r_t ，如下：

$$r_t = \begin{cases} 1, & \text{if } a_t = y_t \\ 0, & \text{if } a_t \neq y_t \end{cases} \quad (0-2)$$

其中， $y_t \in 0,1$ 是时刻 t 真实的学习者作答结果， $y_t = 0$ 表示学习者作答错误， $y_t = 1$ 表示学习者作答正确。设置折扣系数 $\gamma \in [0,1]$ 。在折扣系数作用下，从当前时刻 t 开始，未来折扣奖励之和，记为折扣回报，如下：

$$R_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k} \quad (0-3)$$

其中， R_t 表示从时刻 t 开始的未来折扣奖励之和。

价值网络记为 $V(s_t; \theta_v)$ ，用来获取当前状态 s_t 以及下一时刻状态 s_{t+1} 的价值 $V(s_t)$ 和 $V(s_{t+1})$ ，可以计算时间差分误差（TD 误差）。

策略网络记为 $\pi(a_t | s_t; \theta_\pi)$ ，在已知当前状态 s_t 条件下，根据时间差分误差，优化知识追踪模型的动作输出，使得预测的学习者动作趋向环境给出的奖励最大值。

本模型的目标是，策略网络基于状态 s_t 做出动作 a_t ，即预测学习者会作答正确或错误；得到智能导学系统的奖励 r_t 和下一时刻的状态 s_{t+1} ；根据价值网络计算出 TD 误差；策略网络根据 TD 误差判断动作的优劣并优化参数改进自身，使预测得学习者作答表现与真实的学习者表现一致性更好，即下一时刻预测的学习者作答表现得到的奖励更大，如下：

$$\theta_\pi \leftarrow \theta_\pi - \eta_\pi \nabla_{\theta_\pi} [-\log \pi(a_t | s_t) \cdot \delta_t] \quad (0-4)$$

其中， η_π 为策略网络的学习率； $\pi(a_t | s_t)$ 也可视为知识追踪模型建模的给出当前题目条件下学习者作答结果的概率分布，则 $\nabla_{\theta_\pi} [-\log \pi(a_t | s_t)]$ 表示相邻时间步上述分布的动态变化。这也是提出的模型自适应建模条件概率分布动态变化的过程。

3.1.3 符号定义

符号	定义
$G = (C, E)$	知识点表示图
$c_i \in \mathbb{R}^{d_c}$	知识点 c_i 的向量表示
$E_Q \in \mathbb{R}^{Q \times d_e}$	题目嵌入矩阵
z_t	时刻 t 的知识点表示图嵌入向量
s_t, a_t, r_t	时刻 t 的状态、动作、即时奖励
$\gamma \in [0, 1]$	折扣系数
$N^{(k)}(c_i)$	知识点 c_i 的 k 阶邻居集合
$s_{ij}^{(k)}$	k 跳路径强度
$\omega(k) = \alpha^{k-1}$	距离衰减权重
τ_α, τ_β	三支决策上、下阈值
$N^{(\text{pos}, k)}, N^{(\text{bnd}, k)}, N^{(\text{neg}, k)}$	k 阶正域、边界域、负域邻居集合
$\gamma_{\text{neg}} \in [0, 1]$	可学习的负域抑制系数
$V(s_t; \theta_v)$	价值网络
$\pi(a_t s_t; \theta_\pi)$	策略网络

表：符号定义

3.2 模型架构

模型框架如图 3.1 所示。




图 3.1 模型架构

Fig. 3.1 Model architecture

提出的模型主要包括三个网络，协同完成与智能导学系统的交互：第一，基础网络，由策略网络与价值网络共享。该网络在建立学习者知识点表示图的基础上，接收智能导学系统给出的状态信息，建模状态对知识点表示图的作用和影响，在知识点表示图上经过信息传递、信息聚合、迭代传播和图嵌入等步骤，得到学习者的知识表示嵌入向量。第二，价值网络，以知识点表示图的嵌入向量和环境给出的当前奖励为输入，使该网络获得的状态值逐步收敛于环境给出的奖励，并向策略网络输出状态价值的 TD 误差。第三，策略网络，以知识表示图的嵌入向量和当前状态价值的 TD 误差为输入，经过全连接和 softmax 激活函数，输出知识追踪模型的动作概率。

3.3 多阶三支决策的知识点强化表征网络

3.3.1 知识点表示图基础

学习者的知识点表示图记为 $G=(C, E)$ ，其中 C 表示知识点集合。对于任意知识点 $c_i \in C$ ，其向量表示记为 $\mathbf{c}_i \in \mathbb{R}^{d_c}$ ，其中 d_c 为知识点表示维度。 E 表示知识点之间的关系集合，边 $e_{ij}=(c_i, c_j)$ 表示知识点 c_i 与 c_j 之间的关联关系，其向量表示记为 $\mathbf{e}_{ij} \in \mathbb{R}^{d_e}$ ，其中 d_e 为关系表示维度。本文采用余弦相似度对知识点之间的关系强度进行建模，其计算方式如下：

$$e_{ij} = \frac{\mathbf{c}_i \cdot \mathbf{c}_j}{\|\mathbf{c}_i\| \|\mathbf{c}_j\|} \quad (0-5)$$

3.3.2 知识点表示图的嵌入

基础网络记为 $\phi(s_i; \lambda)$ ，输入为环境状态 $s_t = q_t$ （当前题目），输出为受题目作用的知识表示图的嵌入向量 $\mathbf{z}_t$ 。

(1) 题目增强

学习者练习题目的过程中，其知识点表示图会受到题目的作用发生演化。使用注意力机制建模上述过程，具体如下：

$$\alpha_i^t = \text{softmax}_i \left(\frac{\mathbf{q}_t \mathbf{W}_q \cdot (\mathbf{c}_i \mathbf{W}_k)^T}{\sqrt{d_c}} \right) \quad (0-6)$$

$$\mathbf{c}'_i = \mathbf{c}_i + \alpha_i^t \cdot (\mathbf{q}_t \mathbf{W}_v) \quad (0-7)$$

其中， d_c 是知识点表示向量维数， $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v \in \mathbb{R}^{d_c \times d_c}$ 为嵌入矩阵， $\mathbf{c}'_i$ 为题目增强后的知识点表示。

(2) 多阶表征

使用三支决策对知识点进行表征。针对现有方法仅在一阶邻域空间进行概念划分的局限，本文提出一种多阶邻居显式分离机制。

多阶邻居集合定义：

对于目标知识点 c_i ，定义其 k 阶邻居集合为：

$$N^{(k)}(c_i) = \{c_j \in C \mid d(c_i, c_j) = k\} \quad (0-8)$$

其中 $d(c_i, c_j)$ 表示知识点 c_i 到 c_j 的最短路径长度。本文设置 $k \in 1, 2$ ，即考虑一阶和二阶邻居。通过显式提取不同阶数的邻居集合，保持各阶邻域之间的独立性，从而避免图神经网络隐式多跳传播过程中不同阶信息混合所带来的语义干扰。

k 跳路径强度定义：

$$s_{ij}^{(k)} = \begin{cases} e_{ij}, & k=1 \text{ (一阶直接使用权重边)} \\ \max_{c_m \in N^{(1)}(c_i)} [e_{im} \cdot e_{mj}], & k=2 \text{ (二阶去最大路径强度)} \end{cases} \quad (0-9)$$

距离衰减权重：

为体现“距离越远、影响越弱”的认知规律，引入指数衰减函数：

$$\omega(k) = \alpha^{k-1} \quad (0-10)$$

其中衰减系数 $\alpha = 0.5$ 。当 $k=1$ 时， $\omega(1)=1$ ，一阶邻居权重完整保留；当 $k=2$ 时， $\omega(2)=0.5$ ，二阶邻居权重衰减至一半。

三支决策阈值设定：

本文采用固定阈值策略，基于实验验证设定：

$$\tau_{\alpha} = 0.7 \text{ (上阈值, 正域分界线)} \quad (0-11)$$

$$\tau_{\beta} = 0.3 \text{ (下阈值, 负域分界线)} \quad (0-12)$$

三域划分规则：

在每一阶邻居集合 $N^{(k)}(c_i)$ 上，独立执行三支决策划分，形成正域、边界域与负域，具体定义如下：

正域（高相似度邻居）：

$$N^{(\text{pos},k)}(c_i) = \{c_j \in N^{(k)}(c_i) \mid \omega(k) \cdot s_{ij}^{(k)} \geq \tau_{\alpha}\}$$

边界域（中等相似度邻居）：

$$N^{(\text{bnd},k)}(c_i) = \{c_j \in N^{(k)}(c_i) \mid \tau_{\beta} < \omega(k) \cdot s_{ij}^{(k)} < \tau_{\alpha}\}$$

负域（低相似度邻居）： $N^{(\text{neg},k)}(c_i) = \{c_j \in N^{(k)}(c_i) \mid \omega(k) \cdot s_{ij}^{(k)} \leq \tau_{\beta}\}$

其中， $s_{ij}^{(k)}$ 表示 k 跳路径强度， $\omega(k)$ 为距离衰减权重，且满足 $\tau_{\alpha} > \tau_{\beta}$ 。

(3) 信息传递（差异化消息传递）

建模多阶邻域范围内目标知识点的区域差异化信息传递过程。对于 k 阶邻居集合 $N^{(k)}(c_i)$ 中的每个邻居节点 c_j ，根据其所属区域采用不同的信息传递策略，具体定义如下：

正域消息传递（增强有效信息）：

$$\mathbf{m}_{j \rightarrow i}^{(\text{pos},k,l)} = \text{MLP}_{\text{pos}}([\mathbf{h}_i^{(l)} \parallel \mathbf{h}_j^{(l)} \parallel \mathbf{e}_{ij}]) \cdot \omega(k) \quad (0-13)$$

边界域消息传递（平衡不确定信息）：

$$\alpha_{ij}^{(l)} = \text{Attention}(\mathbf{h}_i^{(l)}, \mathbf{h}_j^{(l)}) = \frac{\exp(\mathbf{h}_i^{(l)T} \mathbf{W}_{\text{att}} \mathbf{h}_j^{(l)})}{\sum_{c_m \in N^{(\text{bnd},k)}(c_i)} \exp(\mathbf{h}_i^{(l)T} \mathbf{W}_{\text{att}} \mathbf{h}_m^{(l)})} \quad (0-14)$$

$$\mathbf{m}_{j \rightarrow i}^{(\text{bnd},k,l)} = \alpha_{ij}^{(l)} \cdot \mathbf{h}_j^{(l)} \cdot \omega(k) \quad (0-15)$$

负域消息传递（抑制噪声干扰）：

$$\mathbf{m}_{j \rightarrow i}^{(\text{neg},k,l)} = -\gamma_{\text{neg}} \cdot \text{MLP}_{\text{neg}}([\mathbf{h}_i^{(l)} \parallel \mathbf{h}_j^{(l)} \parallel \mathbf{e}_{ij}]) \cdot \omega(k) \quad (0-16)$$

其中：

$\text{MLP}_{\text{region}}(\cdot)$ 表示多层感知机， $\text{region} \in \{\text{pos}, \text{neg}\}$

$\parallel$ 表示向量拼接操作

负号用于刻画负域邻居对目标知识点表示更新的抑制作用

$\gamma_{\text{neg}} \in [0,1]$ 是可学习的抑制系数

$\mathbf{h}_j^{(l)}$ 表示来自第 k 阶、区域 r 的邻居节点 c_j 在第 l 层的表示

$\mathbf{W}_{\text{att}} \in \mathbb{R}^{d_c \times d_c}$ 为注意力权重矩阵

设计理念说明：

正域：使用 ReLU 激活的 MLP，保留正向激活，增强有效信息传递

边界域：使用注意力机制，动态评估不确定邻居的贡献度

负域：使用负号和抑制系数，削弱低相似度邻居的噪声影响

(4) 信息聚合（层次化融合）

目标知识点分别聚合来自不同阶、不同区域邻居的信息，并在此基础上执行层次化融合更新，表示如下：

区域内聚合（同一阶、同一区域内的消息聚合）：

$$\mathbf{m}_i^{(\text{pos},k,l)} = \text{Mean}\left(\{\mathbf{m}_{j \rightarrow i}^{(\text{pos},k,l)} \mid c_j \in N^{(\text{pos},k)}(c_i)\}\right) \quad (0-17)$$

$$\mathbf{m}_i^{(\text{bnd},k,l)} = \text{Mean}\left(\{\mathbf{m}_{j \rightarrow i}^{(\text{bnd},k,l)} \mid c_j \in N^{(\text{bnd},k)}(c_i)\}\right) \quad (0-18)$$

$$\mathbf{m}_i^{(\text{neg},k,l)} = \text{Mean}\left(\{\mathbf{m}_{j \rightarrow i}^{(\text{neg},k,l)} \mid c_j \in N^{(\text{neg},k)}(c_i)\}\right) \quad (0-19)$$

区域间融合（同一阶、不同区域间的消息融合）：

$$\mathbf{m}_i^{(k,l)} = \mathbf{W}_r \cdot [\mathbf{m}_i^{(\text{pos},k,l)} \parallel \mathbf{m}_i^{(\text{bnd},k,l)} \parallel \mathbf{m}_i^{(\text{neg},k,l)}] \quad (0-20)$$

跨阶融合（不同阶的消息融合）：

$$\mathbf{h}_i^{(l+1)} = \sigma\left(\mathbf{W}_h \cdot [\mathbf{h}_i^{(l)} \parallel \mathbf{m}_i^{(1,l)} \parallel \mathbf{m}_i^{(2,l)}] + \mathbf{b}_h\right) \quad (0-21)$$

其中：

$\text{Mean}(\cdot)$ 表示均值聚合函数

$\parallel$ 表示拼接操作

$\mathbf{W}_r, \mathbf{W}_h$ 为可学习参数矩阵

$\mathbf{b}_h$ 为偏置向量

$\sigma(\cdot)$ 为非线性激活函数（如 ReLU 或 Tanh）

(5) 迭代传播

经过 L 轮迭代传播后，最终目标知识点的表示经过一个池化函数得到蕴含子图的表示：

$$\mathbf{h}_{G_i}^L = \text{Readout}_1(\{\mathbf{h}_i^{(L)}\}) \quad (0-22)$$

其中， $\mathbf{h}_i^{(L)}$ 为目标知识点在最终层的表示， Readout_1 是 readout 函数，可以选择均值、求和等函数。

(6) 图嵌入

经过一个读出函数汇聚全体知识点表示，如下：

$$\mathbf{z}_t = \text{Readout}_2(\{\mathbf{h}_i^{(L)} | c_i \in C\}) \quad (0-23)$$

其中， c_i 是知识点表示图中任一知识点； Readout_2 是 readout 函数，可以选择均值、求和等函数，与 Readout_1 不必相同； $\mathbf{z}_t$ 蕴含了知识点表示图中全体知识点的信息。

3.4 基于 Actor-Critic 的模型训练方法

3.4.1 价值网络

价值网络记为 $V(s_t; \theta_V)$ ，输入状态 s_t ，输出状态的价值 $V(s_t)$ 。价值网络与策略网络共享基础网络层，经过知识点更新，得到知识点表示图嵌入向量 $\mathbf{z}_t$ ，将知识点表示图嵌入向量映射为当前时刻的状态价值，如下：

$$\mathbf{z}_t = \phi(s_t; \lambda) \quad (0-24)$$

$$V(s_t) = \text{FC}_V(\mathbf{z}_t) \quad (0-25)$$

其中， FC_V 代表全连接层。

3.4.2 策略网络

策略网络记为 $\pi(a_t | s_t; \theta_\pi)$ ，策略网络与价值网络共享基础网络层，经过知识点更新，得到知识点表示图嵌入向量 $\mathbf{z}_t$ ，经过全连接层得到模型预测结果，如下：

$$\mathbf{z}_t = \phi(s_t; \lambda) \quad (0-26)$$

$$\pi(a_t | s_t) = \text{Softmax}(\text{FC}_\pi(\mathbf{z}_t)) \quad (0-27)$$

其中， FC_π 将知识点表示图嵌入向量压缩至两个维度，再使用 Softmax 将其映射为学习者作答正确或错误的概率； Argmax 将上述二维概率向量映射为 0 或 1，分别表示预测学习者作答错误或作答正确； a_t 作为策略网络的输出动作，即 $a_t \in 0, 1$ 。

3.5 模型训练算法

算法 3.1: KRD-KT 模型训练算法

输入: 价值网络的学习率 η_V , 策略网络的学习率 η_π 。

输出: 价值网络 $V(s_t; \theta_V)$, 策略网络 $\pi(a_t | s_t; \theta_\pi)$ 。

步骤:

a) 随机初始化价值网络参数 θ_V 和策略网络参数 θ_π 。

b) 重复以下操作至训练数据结束:

根据当前状态 s_t , 从策略网络采样得到 $a_t \sim \pi(\cdot | s_t)$, 观测到 r_t, s_{t+1} ;

价值网络分别对状态计算价值: $V(s_t) = \text{FCV}(\phi(s_t; \lambda))$,
 $V(s_{t+1}) = \text{FCV}(\phi(s_{t+1}; \lambda))$;

计算 TD 误差: $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$;

更新价值网络: $\theta_V \leftarrow \theta_V - \eta_V \nabla_{\theta_V} \delta_t^2$;

更新策略网络: $\theta_\pi \leftarrow \theta_\pi - \eta_\pi \nabla_{\theta_\pi} [-\log \pi(a_t | s_t) \cdot \delta_t]$;

c) 算法结束。

3.6 本章小结

本章提出了一个融合强化学习范式与三支决策理论的知识追踪模型 KRD-KT。。针对现有知识追踪模型在动态适应题目分布变化方面的不足, 本章首先建立了基于强化学习的问题框架, 将智能导学系统建模为环境, 知识追踪模型建模为智能体, 通过奖励机制驱动模型动态优化。

模型架构包括三个核心组件: 基础网络采用多阶三支决策机制对知识点进行表征, 通过显式分离多阶邻居并划分正域、边界域和负域, 实现差异化的信息传递和层次化融合; 价值网络评估当前学习状态的价值并计算 TD 误差; 策略网络根据 TD 误差优化预测结果。三个网络协同工作, 共同实现知识追踪的动态预测。

相比传统方法, 本模型的核心改进在于: (1) 引入多阶邻居显式分离机制, 避免隐式传播导致的信息混淆; (2) 基于三支决策对不同相似度的邻居采用差异化处理策略; (3) 通过强化学习框架实现模型对动态概率分布的自适应建模。下一章将通过实验验证模型的有效性。

第4章 实验

在第3章中，本文提出了知识点强化表征驱动的知识追踪模型（KRD-KT）。该模型围绕知识点表征质量不足这一关键问题，在传统知识追踪框架基础上引入结构化表征增强机制，通过多阶邻域建模、距离衰减策略以及三支决策理论，对概念关系图中的邻域信息进行分域筛选与差异化聚合，从而获得更加稳健的知识点表示。

本章通过系统实验对 KRD-KT 模型 的有效性进行验证。实验从预测性能、知识状态表示质量、关键超参数敏感性、模型结构贡献度以及可解释性等多个角度展开，力求全面评估所提出方法的优势与合理性。具体而言，本章首先介绍实验所使用的数据集与预处理流程，其次给出实验环境与参数设置，随后通过多组对比实验与分析，验证 KRD-KT 在不同数据集上的表现，最后对实验结果进行总结。

4.1 实验设置

为验证 KRD-KT 模型在不同规模与不同学习行为分布条件下的泛化能力，本文选取了知识追踪领域中广泛使用的三个公开数据集进行实验，分别为 ASSISTments2009（Assist09）、Junyi Academy（Junyi）以及 EdNet。上述数据集均包含学生作答序列、知识点标注以及作答结果信息，适合用于知识追踪模型的系统评估。

表 4-1 数据集统计信息
【此处插入表格：学生数 / 习题数 / 知识点数 / 交互记录数 / 平均序列长度】

4.1.1 ASSISTments2009 数据集

ASSISTments2009 数据集来源于 ASSISTments 智能辅导系统中的中小学数学课程，记录了学生在真实学习环境中的作答行为。该数据集具有知识点数量适中、作答序列长度较长的特点，能够较好地反映学生知识状态的动态变化过程，因此被广泛用于知识追踪模型的评估。

4.1.2 Junyi 数据集

Junyi 数据集来自 Junyi Academy 在线学习平台，覆盖大量学生与知识点，其规模显著大于 ASSISTments 系列数据集。该数据集不仅包含学生的作答记录，还提供了较为完整的知识点关系信息，适合用于验证 KRD-KT 模型在大规模、稠密知识结构条件下的表现。

4.1.3 EdNet 数据集

EdNet 是一个大规模层级化教育数据集，包含数十万学生的作答行为记录。该数据集作答序列较长、知识点分布复杂，对模型的建模能力与稳定性提出了更高要求，可用于进一步验证 KRD-KT 的泛化性能。

4.1.4 数据预处理

在实验前，本文对三个数据集均进行了统一的数据预处理。首先，将每位学生的交互日志按照时间顺序构建为一条作答序列；其次，删除缺失关键字段（知识点或作答结果）的记录，并剔除异常或无效样本；最后，根据模型输入需求，对过长作答序列进行截断或分段处理，以保证训练过程的稳定性与效率。

在知识点关系建模方面，KRD-KT 以知识点为节点构建概念关系图，并基于相似度或依赖关系定义节点之间的连接强度。在此基础上，模型显式提取目标知识点的一阶与二阶邻域，并引入距离衰减权重，以刻画多阶邻域对当前知识点状态更新的差异化影响。

4.1.5 数据集划分

本文将每个数据集按照学生维度随机划分为训练集、验证集和测试集。训练集用于模型参数学习，验证集用于超参数调节与早停策略选择，测试集用于最终性能评估。为减小随机因素带来的影响，所有实验均重复多次并取平均结果作为最终指标。

4.1.6 实验环境

表 4-2 实 验 环 境 配 置
【此处插入表格：CPU / GPU / OS / Python / PyTorch / CUDA 等】

4.1.7 对比模型

为全面评估 KRD-KT 的性能，本文选取多种具有代表性的知识追踪模型作为基线方法，包括：

- DKT：基于循环神经网络的经典知识追踪模型；
- DKVMN：基于记忆网络的知识追踪方法；
- SAINT：基于 Transformer 架构的序列建模方法；
- GKT：基于图神经网络的知识追踪模型；
- DKTMR：引入多关系知识点表征的改进模型。

上述模型覆盖了当前知识追踪领域中主流的建模范式，能够从不同角度验证 KRD-KT 的有效性。

4.1.8 评估指标

本文从预测性能与知识状态表示质量两个方面对模型进行评估，具体指标包括：

- AUC (Area Under Curve): 衡量模型区分正确与错误作答的能力；
- ACC (Accuracy): 衡量模型预测结果的整体正确率；
- DOA (Degree of Agreement): 衡量模型预测的知识状态与学生真实作答行为之间的一致性，用于评估知识状态表示的可信程度。

4.2 预测性能对比实验

4.2.1 预测性能对比实验

本节通过 AUC 与 ACC 两个指标，对 KRD-KT 模型与各基线模型在不同数据集上的预测性能进行比较。

图 4-1 不同模型在各数据集上的 AUC 对比结果
图 4-2 不同模型在各数据集上的 ACC 对比结果

从实验结果可以看出，KRD-KT 在三个数据集上的 AUC 与 ACC 指标均取得了最优或具有明显竞争力的表现。相较于仅依赖历史作答序列进行建模的模型，KRD-KT 能够更加准确地刻画学生知识状态的演化趋势。

进一步与引入知识结构的模型进行比较可以发现，KRD-KT 仍然表现出更优的预测性能。这表明，仅引入知识点关系并不足以充分提升模型效果，若缺乏对邻域信息质量的区分，容易将噪声或弱相关知识点引入状态更新过程。KRD-KT 通过多阶邻域建模结合距离衰减机制，在利用多跳依赖信息的同时有效抑制远邻噪声，从而获得更加合理的预测结果。

此外，三支决策机制通过对邻域信息进行分域筛选，使模型能够重点利用高相关邻居信息，弱化不确定或干扰性信息，这也是 KRD-KT 在预测性能上取得优势的重要原因之一。

4.2.2 知识状态表示质量对比实验

为进一步验证 KRD-KT 在知识状态建模方面的优势，本文采用 DOA 指标对不同模型的知识状态表示质量进行评估。

图 4-3 不同模型在各数据集上的 DOA 对比结果

实验结果表明，KRD-KT 在所有数据集上的 DOA 值均高于对比模型，说明其预测得到的知识状态与学生真实作答行为之间具有更高的一致性。该结果表明，KRD-KT 不仅在预测性能层面取得提升，同时在知识状态的内部表示质量上也具有明显优势。

这一优势主要来源于模型对知识点表征的强化策略。通过多阶邻域建模，模型能够综合考虑不同层级知识点之间的影响关系；通过距离衰减机制，不同阶邻域对状态更新的贡献被合理区分；而三支决策机制进一步对邻域信息进行结构化筛选，使模型获得更加稳定且符合真实学习规律的知识状态表示。

4.3 消融实验

为验证 KRD-KT 各组成模块的有效性，本文设计了一系列消融实验，包括移除三支决策机制、仅保留一阶邻域、去除距离衰减以及去除强化学习策略等变体模型。

模型简称	说明	对应消融模块
KT-RCR（完整模型）	本文提出的完整三支决策改进版	无
KT-RCR w/o 3WD	移除三支决策使用 GNN 进行邻居聚合	三支决策机制
KT-RCR w/o Multi-order	仅使用一阶邻居，移除二阶邻居分离	多阶邻居分离
KT-RCR w/o Diff-Msg	对所有邻居使用相同的消息传递（如 GCN 式聚合）	差异化消息传递
KT-RCR w/o Decay	移除距离衰减权重（即 $\omega(k)=1$ ）	距离衰减机制
KT-RCR w/o Neg-Supp	移除负域抑制系数（ $\gamma_{\text{neg}}=0$ ）	负域抑制机制
KT-RCR-SL（监督学习版）	移除价值网络，改为监督学习训练	强化学习框架

表 4-3 KRD-KT 消融实验结果

【此处插入消融实验表：AUC / ACC / DOA】

实验结果表明，当任一关键模块被移除时，模型性能均出现不同程度下降。移除三支决策机制后，模型在邻域信息筛选方面能力减弱，容易受到噪声干扰；仅保留一阶邻域时，模型难以刻画知识点之间的多跳依赖关系；去除距离衰减机制

后，高阶邻域信息对状态更新的影响被放大，导致性能下降；去除强化学习策略后，模型在动态调整决策方面能力受限。

整体来看，消融实验结果表明，**KRD-KT** 中各模块通过协同作用共同提升了模型整体性能。

4.4 超参数敏感性分析

为分析 **KRD-KT** 中关键设计对模型性能的影响，本文对以下超参数进行了敏感性实验：

- 距离衰减系数 α ；
- 三支决策阈值 τ_α 与 τ_β ；
- 邻域阶数 k 。

图 4-4 AUC 随距离衰减系数变化的曲线
图 4-5 AUC 随邻域阶数变化的曲线

实验结果显示，当 α 取值较小时，高阶邻域信息被过度削弱，模型难以充分利用多跳依赖关系；随着 α 增大，模型性能逐渐提升；当 α 过大时，远邻影响被放大，噪声累积导致模型性能下降。

在邻域阶数 k 的敏感性实验中，可以观察到模型在中等阶数时取得最佳性能。当 k 取值过小时，模型退化为仅利用局部邻域信息；而当 k 取值过大时，过多低相关邻域被引入，增加了状态更新过程中的噪声干扰。

上述结果验证了 **KRD-KT** 在多阶邻域建模与距离衰减设计上的合理性。

4.5 可视化分析实验

为直观展示 **KRD-KT** 对知识状态动态演化的建模能力，本文选取单个学生的作答序列，对若干知识点在时间维度上的掌握程度进行可视化分析。

图 4-6 **KRD-KT** 知识状态演化热力图

从图中可以观察到，当学生在某一知识点上作答正确或错误时，该知识点的掌握程度发生明显变化。同时，其一阶邻域知识点的状态也会产生相应联动，而二阶邻域知识点的变化幅度相对较小。这种由近及远逐渐减弱的状态变化趋势，与 **KRD-KT** 中引入的距离衰减机制一致。

该结果表明，**KRD-KT** 能够在时间维度上合理建模知识状态演化过程，并捕捉知识点之间的结构化影响关系。

进一步地，本文对 KRD-KT 在特定时间步下的三支决策结果进行分析，展示邻域知识点在正域、边界域与负域中的划分情况。

图 4-7 三支决策邻域划分示意图

分析结果表明，KRD-KT 能够显式区分对当前知识点有积极影响、不确定影响以及潜在干扰的邻域信息。正域知识点在状态更新中起到主要促进作用，边界域知识点体现出情境相关的不确定性，而负域知识点则可能对状态更新产生干扰，需要被抑制。

这种结构化的邻域划分，直观展示了模型对邻域信息的差异化处理过程，有助于理解知识状态变化背后的潜在机制。

4.6 本章小结

本章通过多组实验系统评估了**知识点强化表征驱动的知识追踪模型（KRD-KT）**的有效性。实验结果表明，KRD-KT 在预测性能、知识状态表示质量以及模型可解释性等方面均优于多种基线模型。多阶邻域建模、距离衰减机制与三支决策理论在模型中协同作用，使得 KRD-KT 能够在复杂学习行为场景下获得更加稳健、可信的知识状态表示

第5章 总结与展望

5.1 论文工作总结

本文针对现有知识追踪方法在知识点表征质量、多跳邻域建模、邻域信息质量区分以及动态学习过程自适应等方面的不足，提出了一种知识点强化表征驱动的知识追踪模型（KRD-KT）。该模型从结构化建模与决策机制两个层面进行系统改进，主要工作总结如下：

第一，提出基于三支决策的邻域差异化划分机制。针对现有图神经网络方法将所有邻域知识点同质化处理的问题，本文引入三支决策理论，依据知识点间的相似度与阈值参数的关系，将邻居知识点显式划分为正域、边界域和负域三类，从理论层面明确了邻域信息的质量边界。在此基础上，对三类邻域分别采用增强聚合、注意力加权和抑制传播的差异化信息传递策略，有效降低了低质量邻域信息对知识状态更新的噪声干扰。

第二，构建多阶邻域显式建模机制。针对现有方法多跳依赖通过层叠消息传递隐式实现、不同阶次邻域信息混合聚合的问题，本文设计了一阶和二阶邻域的分层建模方案，通过独立的聚合矩阵分别捕捉不同阶次邻域对目标知识点的差异化影响，并采用层次化融合策略将多阶信息有序整合，实现了对多跳依赖的可控显式建模。

第三，引入 Actor-Critic 强化学习框架实现动态自适应建模。针对监督学习范式训练完成后决策机制固定、难以适应动态学习过程的问题，本文将智能导学系统建模为强化学习环境，将知识追踪模型建模为智能体，通过 Actor 网络生成作答预测策略、Critic 网络评估策略的长期效益，依据每个时间步的奖励信号动态调整知识状态表示，使模型具备对动态题目分布的自适应能力。

在 ASSISTments2009、Junyi Academy 和 EdNet 三个公开数据集上的系统实验表明，KRD-KT 模型在预测性能（AUC、ACC）和知识状态表示质量（DOA）指标上均优于 DKT、SAKT、GKT 等对比基线。消融实验进一步验证了三支决策邻域划分、多阶显式建模和强化学习框架三个核心模块各自的有效性，可视化分析也展示了模型对知识状态演化过程的合理建模能力。

5.2 未来研究展望

尽管本文提出的 KRD-KT 模型在知识追踪任务上取得了较好的结果，但仍存在若干值得进一步探索的方向：

第一，三支决策阈值的自适应学习。本文的阈值参数 α 和 β 通过交叉验证确定，属于静态超参数。未来可探索将阈值设计为与知识点特征相关的动态参数，由模型端到端学习，从而更好地适应不同知识领域和学习者群体的差异。

第二，异构图结构的引入。本文的知识点图主要建模知识点间的相似关系，未来可进一步构建包含学习者、题目、知识点等多类实体的异构图，通过更丰富的结构信息增强知识点表征，提升模型对复杂学习场景的刻画能力。

第三，多模态学习数据的融合。当前模型主要利用题目 ID 和作答结果作为输入，未来可引入题目文本语义、作答时间、错误类型等多模态信息，结合大语言模型的语义理解能力进一步丰富知识状态表示。

第四，模型计算效率的优化。强化学习框架的引入增加了训练复杂度，在大规模教育数据集上的计算效率仍有提升空间。未来可探索轻量化的 Actor-Critic 结构设计，或通过知识蒸馏等方法降低模型推理成本，以满足实际教育系统的部署需求。

第五，在真实教学场景中的应用验证。本文实验基于公开数据集，未来可与实际智能导学系统合作，在真实在线教育环境中开展用户实验，进一步验证模型的实用性和可靠性，并根据真实反馈持续优化模型设计。

致 谢

时光荏苒，研究生阶段的学习生活即将画上句号。回首这段岁月，充满了挑战与收获，而这一切都离不开众多师长、同学和家人的支持与帮助。在论文完成之际，谨向所有给予我关怀与指导的人表达最诚挚的感谢。

首先，衷心感谢我的导师张凯老师。恩师治学严谨、思维敏锐，在论文选题、研究方向确定以及撰写修改的每一个阶段，都给予了悉心的指导和宝贵的建议。导师广博的学识和对学术的执着热情深深感染了我，让我在面对困难时始终保持信心和方向。

感谢长江大学计算机科学学院各位老师们在研究生阶段给予的教导与帮助，是你们的言传身教让我打下了扎实的学术基础。感谢课题组的同学们，大家在学习和科研中互相支持、共同进步，共同度过了许多充实而难忘的日子。

感谢论文评审专家和答辩委员会的老师，你们认真负责的审阅和中肯的意见将进一步提升本文的质量。

最后，最深沉的感谢献给我的家人。感谢父母多年来无私的付出和默默的支持，你们的理解与鼓励是我前行最坚实的后盾。

谨以此文，献给所有陪伴我走过这段旅程的人。

参 考 文 献

- [1] 王宇, 朱梦霞, 杨尚辉, 等. 深度知识追踪模型综述和性能比较[J]. 软件学报, 2023, 34(3): 1365-1395.
- [2] 刘铁园, 陈威, 常亮, 等. 基于深度学习的知识追踪研究进展[J]. 计算机研究与发展, 2021, 59(1): 81-104.
- [3] 陈之斌, 单志龙. 知识追踪研究进展[J]. 计算机科学, 2022, 49(10): 83-95.
- [4] 梁琨, 任依梦, 尚余虎, 等. 深度学习驱动的知识追踪研究进展综述[J]. 计算机工程与应用, 2021, 57(21): 41-58.
- [5] Abdelrahman G, Wang Q, Nunes B. Knowledge tracing: A survey[J]. ACM Computing Surveys, 2023, 55(11): 1-37.
- [6] Shen S, Liu Q, Huang Z, et al. A survey of knowledge tracing: Models, Variants, and Applications[J]. IEEE Transactions on Learning Technologies, 2024.
- [7] Song X, Li J, Cai T, et al. A survey on deep learning based knowledge tracing[J]. Knowledge-Based Systems, 2022, 258: 110036.
- [8] Corbett A T, Anderson J R. Knowledge tracing: Modeling the acquisition of procedural knowledge[J]. User modeling and user-adapted interaction, 1994, 4(4): 253-278.
- [9] Cai L, Choi K, Hansen M, et al. Item response theory[J]. Annual Review of Statistics and Its Application, 2016, 3: 297-321.
- [10] Piech C, Bassen J, Huang J, et al. Deep knowledge tracing[C]//Proc of the 29th Annual Conference on Neural Information Processing Systems. Montreal: Curran Associates, 2015: 505-513.
- [11] Zhang J, Shi X, King I, et al. Dynamic key-value memory networks for knowledge tracing[C]//Proc of the 26th International Conference on World Wide Web. New York: ACM Press, 2017: 765-774.
- [12] 李浩君, 方璇, 戴海容. 基于自注意力机制和双向 GRU 神经网络的深度知识追踪优化模型[J]. 计算机应用研究, 2022, 39(3): 732-738.
- [13] 周东岱, 董晓晓, 顾恒年, 等. 基于双流结构和多知识点映射结构改进的深度知识追踪模型[J]. 现代教育技术, 2022, 32(8): 111-118.
- [14] 王士进, 吴金泽, 张浩天, 等. 可信的端到端深度学生知识画像建模方法[J]. 计算机研究与发展, 2023, 60(8): 1822-1833.
- [15] 王文涛, 马慧芳, 舒跃育, 等. 基于上下文表示的知识追踪方法[J]. 计算机工程与科学, 2022, 44(9): 1693-1701.
- [16] 琚生根, 康睿, 赵容梅, 等. 多知识点融合嵌入的深度知识追踪模型[J]. 软件学报, 2022, 34(11): 5126-5142.
- [17] Liu Q, Huang Z, Yin Y, et al. EKT: Exercise-aware knowledge tracing for student performance prediction[J]. IEEE Trans on Knowledge and Data Engineering, 2019, 33(1): 100-115.
- [18] 李晓光, 魏思齐, 张昕, 等. LFKT: 学习与遗忘融合的深度知识追踪模型[J]. 软件学报, 2021, 32(3): 818-830.
- [19] Huang C, Wei H, Huang Q, et al. Learning consistent representations with temporal and causal enhancement for knowledge tracing[J]. Expert Systems with Applications, 2024, 245: 123128.

- [20] Choi Y, Lee Y, Cho J, et al. Towards an appropriate query, key, and value computation for knowledge tracing[C]//Proc of the 7th ACM conference on learning@ scale. New York: ACM Press, 2020: 341-344.
- [21] Pandey S, Karypis G. A self-attentive model for knowledge tracing[C]//Proc of the 12th International Conference on Educational Data Mining. Montreal: International Educational Data Mining Society, 2019: 384-389.
- [22] 陈成, 董永权, 贾瑞, 等. FKA-DKT: 融合知识与能力的深度知识追踪模型[J/OL]. 南京师 大 学 报 (自 然 科 学 版), 1-11[2024-06-24]. <http://kns.cnki.net/kcms/detail/32.1239.n.20240604.0953.002.html>.
- [23] 赵琰, 马慧芳, 王文涛, 等. 可靠响应表示增强的知识追踪方法[J]. 计算机工程与科学, 2024, 46(3): 535-544.
- [24] 贾瑞, 董永权, 刘源, 等. 知识点相关性与遗忘程度融合的深度知识追踪模型[J/OL]. 计 算 机 研 究 与 发 展 , 1-11[2024-06-25]. <http://kns.cnki.net/kcms/detail/11.1777.TP.20240219.1356.018.html>.
- [25] 许智宏, 张惠斌, 董永峰, 等. 问题特征增强的知识追踪模型[J/OL]. 计算机科学与探索, 1-12[2024-06-25]. <http://kns.cnki.net/kcms/detail/11.5602.TP.20231129.1551.002.html>.
- [26] Song X, Li J, Lei Q, et al. Bi-CLKT: Bi-graph contrastive learning based knowledge tracing[J]. Knowledge-Based Systems, 2022, 241: 108274.
- [27] Abdelrahman G, Wang Q. Deep graph memory networks for forgetting-robust knowledge tracing[J]. IEEE Trans on Knowledge and Data Engineering, 2022.
- [28] 董永峰, 黄港, 薛婉若, 等. 融合 IRT 的图注意力深度知识追踪模型[J]. 计算机科学, 2023, 50(3): 173-180.
- [29] 闫秋艳, 司雨晴, 袁冠, 等. 基于学生-问题关联的异构图知识追踪模型[J]. 电子学报, 2023, 51(12): 3549-3556.
- [30] 张凯, 付姿姿, 覃正楚. 时空相关性融合表征的知识追踪模型[J]. 计算机应用研究, 2024, 41(5): 1381-1387.
- [31] Nakagawa H, Iwasawa Y, Matsuo Y. Graph-based knowledge tracing: modeling student proficiency using graph neural network[C]//Proc of IEEE/WIC/ACM International Conference on Web Intelligence. New York: ACM Press, 2019: 156-163.
- [32] Yang Y, Shen J, Qu Y, et al. GIKT: a graph-based interaction model for knowledge tracing[C]//Machine Learning and Knowledge Discovery in Databases: European Conference. Springer International Publishing, 2021: 299-315.

- [33] 郑浩东, 马华, 谢颖超, 等. 融合遗忘因素与记忆门的图神经网络知识追踪模型[J]. 计算机应用, 2023, 43(9): 2747-2752.
- [34] Duan Z, Dong X, Gu H, et al. Towards more accurate and interpretable model: Fusing multiple knowledge relations into deep knowledge tracing[J]. Expert Systems with Applications, 2024, 243: 122573.
- [35] Qin C, Hu W, Du F, et al. Graph attention-enhanced knowledge tracing: unveiling exercise variability and long-term dependencies[C]//Proc of 12th International Conference on Information and Education Technology. NJ: IEEE Press, 2024: 482-488.
- [36] Cui C, Yao Y, Zhang C, et al. DGEKT: a dual graph ensemble learning method for knowledge tracing[J]. ACM Transactions on Information Systems, 2024, 42(3): 1-24.
- [37] Song X, Li J, Tang Y, et al. Jkt: A joint graph convolutional network based deep knowledge tracing[J]. Information Sciences, 2021, 580: 510-523.
- [38] Gan W, Sun Y, Sun Y. Knowledge structure enhanced graph representation learning model for attentive knowledge tracing[J]. International Journal of Intelligent Systems, 2022, 37(3): 2012-2045.
- [39] Yang H, Hu S, Geng J, et al. Heterogeneous graph-based knowledge tracing with spatiotemporal evolution[J]. Expert Systems with Applications, 2024, 238: 122249.
- [40] Ni Q, Wei T, Zhao J, et al. HHSKT: A learner-question interactions based heterogeneous graph neural network model for knowledge tracing[J]. Expert Systems with Applications, 2023, 215: 119334.
- [41] 宗晓萍, 陶泽泽. 基于掌握速度的知识追踪模型[J]. 计算机工程与应用, 2021, 57(6): 117-123.
- [42] Pu Y, Liu F, Shi R, et al. ELAKT: Enhancing locality for attentive knowledge tracing[J]. ACM Transactions on Information Systems, 2024, 42(4): 1-27.
- [43] Tang Y, Yang W, Xie Y, et al. Deep knowledge tracing method based on enhancing knowledge graph embedding[C]//Proc of the 2024 7th International Conference on Computer Information Science and Artificial Intelligence. New York: ACM Press, 2024: 4891-4900.
- [44] Knowledge Tracing as Language Processing: A Large-Scale Autoregressive Paradigm[C]//Proc of the 25th International Conference on Artificial Intelligence in Education. 2024.
- [45] Beck M, et al. DKT2: Revisiting applicable and comprehensive knowledge tracing in large-scale data[C]//Machine Learning and Knowledge Discovery in Databases. Research Track (ECML PKDD 2025). Springer, 2025.

- [46] Yang H, et al. LLM supporting knowledge tracing leveraging global subject and student specific knowledge graphs[J]. Knowledge-Based Systems, 2025, 310: 112958.
- [47] Baig D, Nurbakova D, Calabretto S, et al. Enhancing knowledge tracing with large language models (LLMs)[C]//Artificial Intelligence in Education. Posters and Late Breaking Results, Workshops and Tutorials, Industry and Innovation Tracks, Practitioners, Doctoral Consortium, Blue Sky, and WideAIED. 2025.
- [48] Lee U, Yoon S, Yun J S, et al. Difficulty-focused contrastive learning for knowledge tracing with a large language model-based difficulty prediction[C]//Proc of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). 2024: 4891-4900.
- [49] Yu Y, Zhou Y, Zhu Y, et al. ECKT: Enhancing code knowledge tracing via large language models[J]. 2024.
- [50] Difficulty aware programming knowledge tracing via large language models[J]. Scientific Reports, 2025, 15: 21395.
- [51] Pu Y, et al. Embedding cognitive framework with self-attention for interpretable knowledge tracing[J]. Scientific Reports, 2022, 12: 17536.
- [52] Huang C, Wei H, Huang Q, et al. Learning consistent representations with temporal and causal enhancement for knowledge tracing[J]. Expert Systems with Applications, 2024, 245: 123128.
- [53] Lu Y, Wang D, Chen P, et al. Interpreting deep learning models for knowledge tracing[J]. International Journal of Artificial Intelligence in Education, 2022: 1-24.
- [54] Wang Y, Huo Y, Yang C, et al. Knowledge ontology enhanced model for explainable knowledge tracing[J]. Journal of King Saud University-Computer and Information Sciences, 2024, 36(5): 102065.
- [55] Yeung C K. Deep-IRT: Make deep learning based knowledge tracing explainable using item response theory[J]. arXiv preprint arXiv:1904.11738, 2019.
- [56] Tong C, Ren C. Deep knowledge tracing and cognitive load estimation for personalized learning path generation using neural network architecture[J]. Scientific Reports, 2025, 15: 24925.
- [57] Wu Z, et al. Reinforcement learning enhanced graph neural network with relative entropy[C]//IEEE International Conference on Data Engineering (ICDE). 2025.

- [58] Corbett A T, Anderson J R. Knowledge tracing: Modeling the acquisition of procedural knowledge[J]. *User Modeling and User-Adapted Interaction*, 1994, 4(4): 253-278.
- [59] Piech C, Bassen J, Huang J, et al. Deep knowledge tracing[C]//Proc of the 29th International Conference on Neural Information Processing Systems. Montreal: Curran Associates, 2015: 505-513.
- [60] Nakagawa H, Iwasawa Y, Matsuo Y. Graph-based knowledge tracing: modeling student proficiency using graph neural network[C]//Proc of IEEE/WIC/ACM International Conference on Web Intelligence. New York: ACM Press, 2019: 156-163.
- [61] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[C]//Proc of the 3rd International Conference on Learning Representations. San Diego: ICLR, 2015.
- [62] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Proc of the 31st International Conference on Neural Information Processing Systems. Long Beach: Curran Associates, 2017: 6000-6010.
- [63] Pandey S, Karypis G. A self-attentive model for knowledge tracing[C]//Proc of the 12th International Conference on Educational Data Mining. Montreal: International Educational Data Mining Society, 2019: 384-389.
- [64] Gilmer J, Schoenholz S S, Riley P F, et al. Neural message passing for quantum chemistry[C]//Proc of the 34th International Conference on Machine Learning. Sydney: PMLR, 2017: 1263-1272.
- [65] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]//Proc of the 5th International Conference on Learning Representations. Toulon: ICLR, 2017.
- [66] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[C]//Proc of the 6th International Conference on Learning Representations. Vancouver: ICLR, 2018.
- [67] Nakagawa H, Iwasawa Y, Matsuo Y. Graph-based knowledge tracing: modeling student proficiency using graph neural network[C]//Proc of IEEE/WIC/ACM International Conference on Web Intelligence. New York: ACM Press, 2019: 156-163.
- [68] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. *Nature*, 2015, 518(7540): 529-533.
- [69] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. Cambridge: MIT Press, 2018.

[70] Liu Q, Huang Z, Yin Y, et al. EKT: Exercise-aware knowledge tracing for student performance prediction[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 33(1): 100-115.

[71] Zhou Y, Huang C, Hu Q, et al. Personalized exercise recommendation via deep reinforcement learning[C]//Proc of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM Press, 2021: 2304-2314.

个 人 简 介

1. 基本情况

姓名: *** 性别: 男 出生年月: 2000 年 1 月 籍贯: *****

政治面貌: 共青团员

2018 年-2022 年 本科 ****

2022 年-2025 年 硕士 ****

2019 年通过国家英语四级考试

2. 专利

[1] **等. 一种知识点动态协同的知识追踪系统[P]. 中国专利, CN117077737B, ZL202311055600.3, 2024-03-15. (已授权, 导师第一作者, 本人第二作者)

[2] **等. 一种全局知识汇聚感知的知识追踪系统[P]. 中国专利, CN117057422B, ZL202311066211.0, 2024-04-02. (已授权, 导师第一作者, 本人第三作者)

3. 获奖情况

[1] 2024 年 4 月参加第十五届蓝桥杯全国软件和信息技术专业人才大赛 (python 程序设计研究生组), 获省二等奖, 授奖单位为工业和信息化部人才交流中心、蓝桥杯大赛组委会。

[2] 2024 年 5 月通过国家统一组织的计算机技术与软件专业技术资格考试, 取得中级资格证书。

4. 论文

[1] **等. 知识追踪与人工智能的课堂教学探究[J]. 科教导刊(电子版), 2023(12): 10-12. (导师第一作者, 本人第二作者)